Estadística Inferencial clásica

Métodos clásicos

César Galindo

Índice

1. Preliminares: modelo, muestra, estadísticos **2**
1.1. Modelo paramétrico y muestra i.i.d. . . . 2
1.2. Ejemplos resueltos de modelado . . . 2

2. Estimación puntual: sesgo, varianza, MSE; MLE **4**
2.1. Criterios de calidad . . . 4
2.2. Media y varianza muestral (pruebas completas) . . . 5
2.3. Máxima verosimilitud (MLE): teoría y pruebas . . . 5
2.4. Ejemplos resueltos de MLE y estimación puntual . . . 6

3. Intervalos de confianza: pivotes, CLT, t y χ^2 **7**
3.1. Pivotes e intervalos . . . 7
3.2. IC aproximado para μ (CLT) y tamaño de muestra . . . 8
3.3. Normal exacto: χ^2 para σ^2 y t para μ . . . 8
3.4. Cómo encontrar los cuantiles t y χ^2 . . . 9
3.5. Ejemplos resueltos de IC . . . 13

4. Pruebas de hipótesis: nivel, potencia, p-value; razón de verosimilitud **15**
4.1. Definiciones básicas . . . 15
4.2. Neyman–Pearson (hipótesis simples) con prueba completa . . . 16
4.3. Pruebas para media: z y t; dualidad IC–prueba . . . 16
4.4. Pruebas para dos muestras y para varianzas . . . 17
4.5. Tabla de pruebas de hipótesis . . . 17
4.6. Ejemplos resueltos de pruebas . . . 18

5. Regresión lineal: mínimos cuadrados, propiedades, inferencia **27**
5.1. Modelo y estimadores OLS . . . 27
5.2. Insesgadez, varianzas y Gauss–Markov (pruebas completas) . . . 28
5.3. Inferencia exacta bajo normalidad . . . 28
5.4. Ejemplos resueltos de regresión con finanzas . . . 29

A. Apéndice A: Prerrequisitos probabilísticos (recordatorio) **30**
A.1. Espacios de probabilidad y variables aleatorias . . . 30
A.2. Esperanza, varianza, covarianza (fórmulas mínimas) . . . 30
A.3. Desigualdades esenciales . . . 31
A.4. Leyes límite: LLN y CLT . . . 31

A.5. Normal, chi-cuadrada y t: relaciones mínimas 31
A.6. Transformaciones y método delta (recordatorio corto) 32

B. Apéndice B: Ejercicios y soluciones completas **32**
B.1. Ejercicios con soluciones 32

1. Preliminares: modelo, muestra, estadísticos

1.1. Modelo paramétrico y muestra i.i.d.

Definición 1.1 (Modelo estadístico paramétrico)**.** Un *modelo estadístico* es una familia $\{P_\theta : \theta \in \Theta\}$ de distribuciones para la muestra $X = (X_1, \dots, X_n)$. En el enfoque frecuentista, θ es una constante desconocida; la aleatoriedad está en X.

Definición 1.2 (Muestra aleatoria i.i.d.)**.** Decimos que $X_1, \dots, X_n$ es una *muestra aleatoria i.i.d.* si son independientes y con la misma distribución.

Definición 1.3 (Estadístico)**.** Un *estadístico* es una función medible $T = h(X_1, \dots, X_n)$.

Lema 1.4 (Media y varianza de la media muestral)**.** *Si $X_1, \dots, X_n$ son i.i.d. con $\mathbb{E}[X_i] = \mu$ y $\mathrm{Var}(X_i) = \sigma^2 < \infty$, entonces*

$$\mathbb{E}[\overline{X}] = \mu, \qquad \mathrm{Var}(\overline{X}) = \frac{\sigma^2}{n}.$$

Solución. Por linealidad, $\mathbb{E}[\overline{X}] = \frac{1}{n}\sum_{i=1}^n \mathbb{E}[X_i] = \mu$. Por independencia, $\mathrm{Var}(\sum X_i) = \sum \mathrm{Var}(X_i) = n\sigma^2$; así $\mathrm{Var}(\overline{X}) = \mathrm{Var}(\sum X_i)/n^2 = \sigma^2/n$.

Observación 1.5 (Plantilla de modelado). **(1)** Define una observación X_i (retorno diario, tiempo entre eventos, etc.).

(2) Decide si i.i.d. es razonable (o como aproximación en una ventana temporal).

(3) Elige parámetro θ (media, volatilidad, tasa de default, β CAPM, etc.).

(4) Elige estadístico(s) (media, varianza, MLE, OLS, etc.).

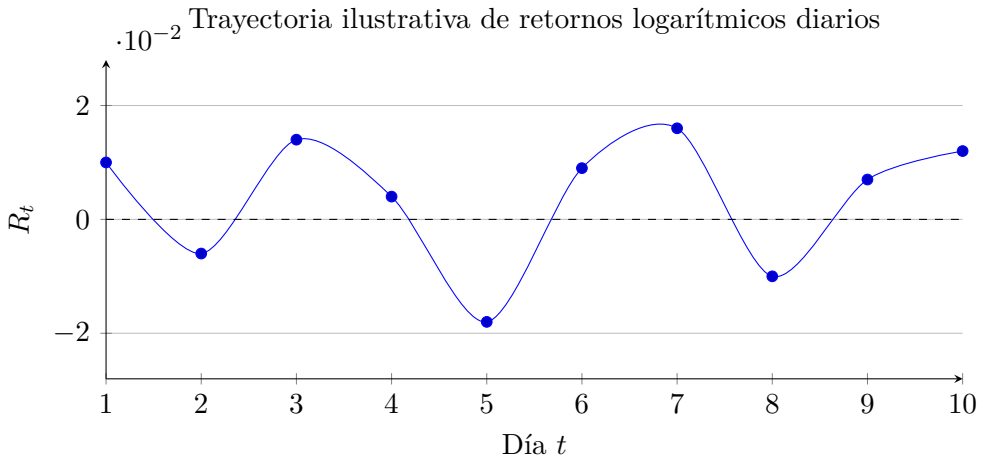
1.2. Ejemplos resueltos de modelado

Ejemplo 1.6 (Retornos logarítmicos (finanzas))**.** Sea P_t el precio de cierre. Define retorno logarítmico diario

$$R_t = \log\left(\frac{P_t}{P_{t-1}}\right).$$

En una ventana corta (mercado "estable"), se usa el modelo $R_1, \dots, R_n$ i.i.d. con $\mathbb{E}[R_i] = \mu$ y $\mathrm{Var}(R_i) = \sigma^2$.

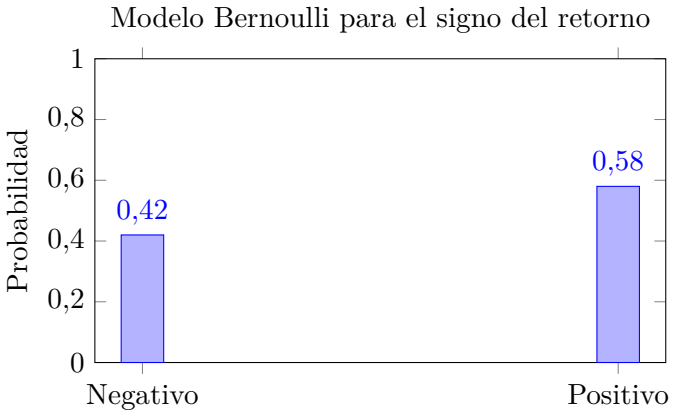
Solución. La hipótesis i.i.d. no es una verdad universal: es una aproximación local. En inferencia clásica, fijamos un modelo *operativo* y cuantificamos incertidumbre sobre μ y σ^2.



Explicación de la figura. La trayectoria no pretende probar normalidad ni independencia; sólo muestra la clase de serie sobre la que luego se estima una media, una varianza y se construyen intervalos o pruebas. En práctica, el signo cambiante de los retornos sugiere que la señal promedio puede ser pequeña respecto al ruido.

Ejemplo 1.7 (Día positivo (finanzas))**.** Define $X_i = \mathbb{1}_{\{R_i>0\}}$. Entonces $X_i \in \{0,1\}$ y se modela como Bernoulli con parámetro $p = \mathbb{P}(R > 0)$; $\overline{X}$ estima p.

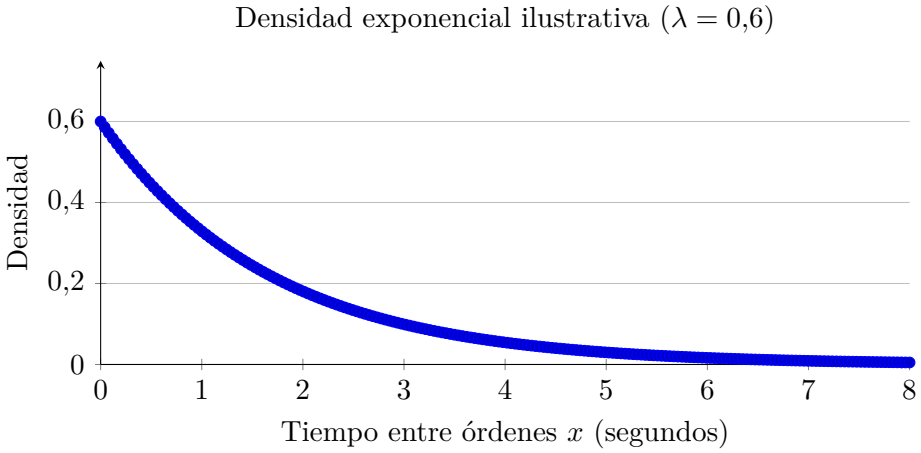
Solución. Bajo Bernoulli(p), $\mathbb{E}[X_i] = p$ y $\mathrm{Var}(X_i) = p(1-p)$. La estimación natural de p es $\widehat{p} = \overline{X}$ (también es MLE; ver Ejemplo 2.13).



Explicación de la figura. La barra de "Positivo" mayor que la de "Negativo" representa un escenario en el que la probabilidad de un día ganador supera 50 %. Este tipo de visualización ayuda a traducir un parámetro abstracto p en una lectura operativa inmediata.

Ejemplo 1.8 (Tiempos entre órdenes (microestructura))**.** Sea X_i el tiempo (en segundos) entre dos órdenes consecutivas en un activo. Un modelo base es $X_i \sim \mathrm{Exp}(\lambda)$ i.i.d.

Solución. Aquí λ es la *intensidad* (órdenes por segundo). El estimador MLE es $\widehat{\lambda} = 1/\overline{X}$ (ver Ejemplo 2.14).



Explicación de la figura. La densidad exponencial decrece rápidamente: tiempos muy cortos entre órdenes son más frecuentes que tiempos largos. En business analytics esto suele interpretarse como actividad concentrada en lapsos breves con eventos largos relativamente raros.

Ejemplo 1.9 (Tasa de defecto (industria / riesgo))**.** Sea $X_i = \mathbb{1}_{\{\text{defecto}\}}$. Se modela $X_i \sim \text{Bern}(p)$ i.i.d. El parámetro p es la tasa de defecto.

Solución. La inferencia clásica produce (i) estimación puntual $\widehat{p}$ y (ii) IC o pruebas sobre p.

2. Estimación puntual: sesgo, varianza, MSE; MLE

2.1. Criterios de calidad

Definición 2.1 (Estimador y estimación)**.** Un *estimador* de θ es una v.a. $\widehat{\Theta} = h(X_1, \ldots, X_n)$. La *estimación* es el valor observado $\widehat{\theta} = h(x_1, \ldots, x_n)$.

Definición 2.2 (Sesgo y MSE)**.**

$$\text{Bias}_\theta(\widehat{\Theta}) = \mathbb{E}_\theta[\widehat{\Theta}] - \theta, \qquad \text{MSE}_\theta(\widehat{\Theta}) = \mathbb{E}_\theta\left[(\widehat{\Theta} - \theta)^2\right].$$

Teorema 2.3 (Descomposición sesgo–varianza)**.** *Para todo estimador* $\widehat{\Theta}$ *con segundo momento finito,*

$$\text{MSE}_\theta(\widehat{\Theta}) = \text{Var}_\theta(\widehat{\Theta}) + \text{Bias}_\theta(\widehat{\Theta})^2.$$

Solución. Sea $b = \mathbb{E}[\widehat{\Theta}] - \theta$. Entonces $\widehat{\Theta} - \theta = (\widehat{\Theta} - \mathbb{E}[\widehat{\Theta}]) + b$. Al cuadrar y tomar esperanza:

$$\mathbb{E}[(\widehat{\Theta} - \theta)^2] = \mathbb{E}[(\widehat{\Theta} - \mathbb{E}[\widehat{\Theta}])^2] + 2b\,\mathbb{E}[\widehat{\Theta} - \mathbb{E}[\widehat{\Theta}]] + b^2 = \text{Var}(\widehat{\Theta}) + b^2.$$

Corolario 2.4 (Insesgadez reduce MSE a varianza)**.** *Si* $\widehat{\Theta}$ *es insesgado, entonces* $\text{MSE}_\theta(\widehat{\Theta}) = \text{Var}_\theta(\widehat{\Theta})$.

Solución. Si Bias $= 0$, aplica Teorema 2.3.

2.2. Media y varianza muestral (pruebas completas)

Definición 2.5 (Media y varianza muestral)**.**

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2.$$

Proposición 2.6 (Insesgadez de $\overline{X}$)**.** *Si* $\mathbb{E}[X_i] = \mu$*, entonces* $\mathbb{E}[\overline{X}] = \mu$*.*

Solución. Es la primera igualdad del Teorema 1.4.

Lema 2.7 (Identidad de descomposición de cuadrados)**.** *Para cualquier números* $x_1, \ldots, x_n$ *y cualquier* $a \in \mathbb{R}$*,*

$$\sum_{i=1}^{n}(x_i - \overline{x})^2 = \sum_{i=1}^{n}(x_i - a)^2 - n(\overline{x} - a)^2, \quad \overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Solución. Escribe $x_i - \overline{x} = (x_i - a) - (\overline{x} - a)$ y expande:

$$\sum (x_i - \overline{x})^2 = \sum (x_i - a)^2 - 2(\overline{x} - a)\sum (x_i - a) + \sum (\overline{x} - a)^2.$$

Pero $\sum(x_i - a) = n(\overline{x} - a)$ y $\sum(\overline{x} - a)^2 = n(\overline{x} - a)^2$. Sustituyendo queda la identidad.

Teorema 2.8 (Insesgadez de S^2)**.** *Si* $X_1, \ldots, X_n$ *son i.i.d. con varianza* σ^2*, entonces* $\mathbb{E}[S^2] = \sigma^2$*.*

Solución. Sea $\mu = \mathbb{E}[X_i]$. Aplica Teorema 2.7 con $a = \mu$ y $x_i = X_i$:

$$\sum (X_i - \overline{X})^2 = \sum (X_i - \mu)^2 - n(\overline{X} - \mu)^2.$$

Toma esperanza:

$$\mathbb{E}\Big[\sum (X_i - \overline{X})^2\Big] = \sum \mathbb{E}[(X_i - \mu)^2] - n\,\mathbb{E}[(\overline{X} - \mu)^2] = n\sigma^2 - n\,\mathrm{Var}(\overline{X}).$$

Por Teorema 1.4, $\mathrm{Var}(\overline{X}) = \sigma^2/n$; así la esperanza vale $(n-1)\sigma^2$. Divide por $n-1$ para obtener $\mathbb{E}[S^2] = \sigma^2$.

Corolario 2.9 (Consistencia de $\overline{X}$)**.** *Si* $\mathrm{Var}(X_i) = \sigma^2 < \infty$*, entonces* $\overline{X} \to \mu$ *en probabilidad cuando* $n \to \infty$*.*

Solución. Por Chebyshev: $\mathbb{P}(|\overline{X} - \mu| \geq \varepsilon) \leq \mathrm{Var}(\overline{X})/\varepsilon^2 = (\sigma^2/n)/\varepsilon^2 \to 0$.

2.3. Máxima verosimilitud (MLE): teoría y pruebas

Definición 2.10 (Verosimilitud y log-verosimilitud)**.** Si la densidad/pmf es $f(x;\theta)$, para datos $(x_1, \ldots, x_n)$ se define

$$L(\theta) = \prod_{i=1}^{n} f(x_i;\theta), \qquad \ell(\theta) = \log L(\theta) = \sum_{i=1}^{n} \log f(x_i;\theta).$$

Un *MLE* es un $\widehat{\theta}$ que maximiza $L(\theta)$ (equiv. $\ell(\theta)$).

Teorema 2.11 (Invarianza del MLE)**.** *Si $\widehat{\theta}$ es MLE de θ y g es una función tal que $g(\widehat{\theta})$ está bien definida, entonces $g(\widehat{\theta})$ es un MLE de $g(\theta)$ (verosimilitud perfilada).*

Solución. Para $u = g(\theta)$ define la verosimilitud perfilada $\widetilde{L}(u) = \sup_{\theta:\, g(\theta)=u} L(\theta)$. Como $L(\widehat{\theta}) \geq L(\theta)$ para toda θ, se tiene $\widetilde{L}(u) \leq L(\widehat{\theta})$ para todo u, con igualdad en $u = g(\widehat{\theta})$. Por tanto $g(\widehat{\theta})$ maximiza $\widetilde{L}$.

Observación 2.12 (Plantilla MLE). **(1)** Escribe $L(\theta)$ y luego $\ell(\theta)$.

(2) Resuelve $\ell'(\theta) = 0$ (o gradiente $= 0$).

(3) Verifica máximo (segunda derivada / concavidad / frontera).

(4) Si piden $g(\theta)$, usa invarianza.

2.4. Ejemplos resueltos de MLE y estimación puntual

Ejemplo 2.13 (Bernoulli: MLE de p)**.** Si $X_i \sim \text{Bern}(p)$, entonces el MLE es $\widehat{p} = \overline{X}$.

Solución. Con $S = \sum x_i$:

$$L(p) = \prod p^{x_i}(1-p)^{1-x_i} = p^S(1-p)^{n-S}, \quad \ell(p) = S\log p + (n-S)\log(1-p).$$

Deriva:

$$\ell'(p) = \frac{S}{p} - \frac{n-S}{1-p} = 0 \iff S(1-p) = p(n-S) \iff \widehat{p} = \frac{S}{n} = \overline{X}.$$

Además $\ell''(p) = -S/p^2 - (n-S)/(1-p)^2 < 0$ para $0 < p < 1$, luego es máximo interior.

Ejemplo 2.14 (Exponencial: MLE de λ)**.** Si $X_i \sim \text{Exp}(\lambda)$ (densidad $\lambda e^{-\lambda x}$, $x \geq 0$), entonces $\widehat{\lambda} = 1/\overline{X}$.

Solución.

$$\ell(\lambda) = \sum(\log\lambda - \lambda x_i) = n\log\lambda - \lambda\sum x_i, \quad \ell'(\lambda) = \frac{n}{\lambda} - \sum x_i.$$

Igualando a cero: $\widehat{\lambda} = n/\sum x_i = 1/\overline{X}$. Como $\ell''(\lambda) = -n/\lambda^2 < 0$, es máximo.

Ejemplo 2.15 (Normal: MLE de μ y σ^2)**.** Si $X_i \sim N(\mu, \sigma^2)$ i.i.d., entonces

$$\widehat{\mu}_{\text{ML}} = \overline{X}, \qquad \widehat{\sigma^2}_{\text{ML}} = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2 = \frac{n-1}{n}S^2.$$

Solución. La log-verosimilitud (omitiendo constantes) es

$$\ell(\mu, \sigma^2) = -\frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2}\sum(x_i - \mu)^2.$$

Para μ:

$$\frac{\partial\ell}{\partial\mu} = \frac{1}{\sigma^2}\sum(x_i - \mu) = 0 \iff \widehat{\mu} = \overline{X}.$$

Sustituye $\mu = \overline{X}$:

$$\ell(\sigma^2) = -\frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2}\sum (x_i - \overline{X})^2.$$

Deriva:

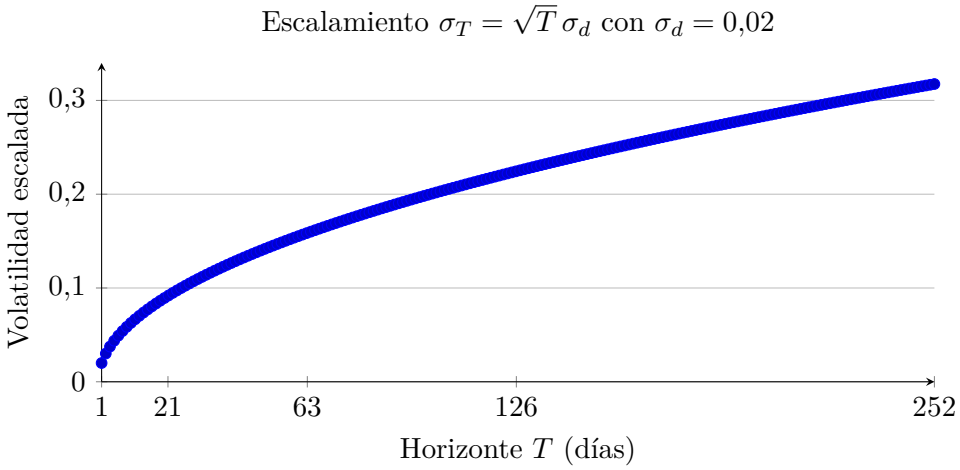
$$\frac{d\ell}{d\sigma^2} = -\frac{n}{2}\frac{1}{\sigma^2} + \frac{1}{2}\frac{\sum (x_i - \overline{X})^2}{(\sigma^2)^2} = 0 \iff \widehat{\sigma^2} = \frac{1}{n}\sum (x_i - \overline{X})^2.$$

La segunda derivada es negativa en el máximo.

Ejemplo 2.16 (Volatilidad anualizada (finanzas): estimación puntual)**.** Con retornos diarios R_i en una ventana estable y modelo $R_i \sim N(\mu, \sigma^2)$:

$$\widehat{\sigma}_{\text{diaria}} = \sqrt{S^2}, \qquad \widehat{\sigma}_{\text{anual}} = \sqrt{252}\,\widehat{\sigma}_{\text{diaria}}.$$

Solución. La insesgadez de S^2 para σ^2 es Teorema 2.8. La anualización usa la regla $\text{Var}(\sum_{t=1}^{T} R_t) = T\sigma^2$ bajo independencia, por lo que la desviación estándar escala como $\sqrt{T}$.



3. Intervalos de confianza: pivotes, CLT, t y χ^2

3.1. Pivotes e intervalos

Definición 3.1 (Intervalo de confianza)**.** Un intervalo aleatorio $[L(X), U(X)]$ es un IC de nivel $1-\alpha$ si $\mathbb{P}_\theta(L(X) \le \theta \le U(X)) = 1-\alpha$ (o $\ge 1-\alpha$).

Definición 3.2 (Pivote)**.** Una v.a. $Q(X, \theta)$ es un *pivote* si su distribución no depende de θ.

Proposición 3.3 (Método del pivote)**.** *Si $Q(X,\theta)$ es pivote y existen $a < b$ con $\mathbb{P}(a \le Q \le b) = 1-\alpha$ y $a \le Q(X,\theta) \le b \iff L(X) \le \theta \le U(X)$, entonces $[L(X), U(X)]$ es un IC $1-\alpha$.*

Solución. Por equivalencia de eventos, sus probabilidades coinciden.

3.2. IC aproximado para μ (CLT) y tamaño de muestra

Teorema 3.4 (CLT (recordatorio operativo)). *Si X_i i.i.d. con $\mathbb{E}[X_i] = \mu$ y $\mathrm{Var}(X_i) = \sigma^2 < \infty$, entonces*

$$\frac{\sqrt{n}(\overline{X} - \mu)}{\sigma} \Rightarrow N(0,1).$$

Observación 3.5. En un curso básico se toma este teorema como prerrequisito (ver Apéndice A).

Teorema 3.6 (IC aproximado para μ con σ conocida). *Para n grande, aproximadamente*

$$\mu \in \left[\overline{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}},\ \overline{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right].$$

Solución. Por Teorema 3.4, $Z_n = (\overline{X}-\mu)/(\sigma/\sqrt{n}) \approx N(0,1)$. Entonces $\mathbb{P}(|Z_n| \le z_{\alpha/2}) \approx 1-\alpha$. Despeja μ.

Corolario 3.7 (Tamaño muestral para margen E). *Si quieres semiancho $\le E$, basta tomar*

$$n \ge \left(\frac{z_{\alpha/2}\sigma}{E}\right)^2.$$

Solución. El semiancho del IC es $z_{\alpha/2}\sigma/\sqrt{n}$; impón $\le E$.

3.3. Normal exacto: χ^2 para σ^2 y t para μ

Teorema 3.8 (Cochran: $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$). *Si $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ i.i.d., entonces*

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}.$$

Solución. Escribe $X_i = \mu + \sigma Z_i$ con $Z_i \sim N(0,1)$ i.i.d. Entonces

$$\sum (X_i - \overline{X})^2 = \sigma^2 \sum (Z_i - \overline{Z})^2.$$

El vector $Z \in \mathbb{R}^n$ es normal estándar e invariante por rotaciones. La descomposición ortogonal $\mathbb{R}^n = \mathrm{span}\{\mathbf{1}\} \oplus \mathbf{1}^\perp$ separa una coordenada (promedio) y $n-1$ coordenadas ortogonales independientes $N(0,1)$. La suma $\sum (Z_i - \overline{Z})^2$ es la suma de cuadrados de esas $n-1$ normales, luego tiene distribución χ^2_{n-1}.

Corolario 3.9 (IC exacto para σ^2). *Sea $\chi^2_{\gamma,\nu}$ el cuantil tal que $\mathbb{P}(\chi^2_\nu \le \chi^2_{\gamma,\nu}) = \gamma$. Entonces un IC exacto $1-\alpha$ para σ^2 es*

$$\sigma^2 \in \left[\frac{(n-1)S^2}{\chi^2_{1-\alpha/2,n-1}},\ \frac{(n-1)S^2}{\chi^2_{\alpha/2,n-1}}\right].$$

Solución. Usa el pivote $Q = (n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$ y encierra Q entre cuantiles de colas iguales: $\mathbb{P}(\chi^2_{\alpha/2,n-1} \le Q \le \chi^2_{1-\alpha/2,n-1}) = 1-\alpha$. Despeja σ^2.

Teorema 3.10 (Pivote t para μ con σ desconocida)**.** *Si $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ i.i.d., entonces*

$$T = \frac{\overline{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Solución. Bajo normalidad, $Z = (\overline{X} - \mu)/(\sigma/\sqrt{n}) \sim N(0,1)$. Por Teorema 3.8, $U = (n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$. Además $\overline{X}$ es independiente de S^2 en el caso normal (misma descomposición ortogonal). Entonces

$$T = \frac{Z}{\sqrt{U/(n-1)}} \sim t_{n-1}$$

por definición de la distribución t.

Corolario 3.11 (IC exacto para μ)**.** *Un IC exacto $1-\alpha$ para μ es*

$$\mu \in \left[\overline{X} - t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}},\ \overline{X} + t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}} \right].$$

Solución. Por Teorema 3.10, $\mathbb{P}(|T| \le t_{1-\alpha/2,n-1}) = 1-\alpha$. Despeja μ.

3.4. Cómo encontrar los cuantiles t y χ^2

Los intervalos y las pruebas de este texto tienen fronteras que son cuantiles. Conviene fijar la convención una sola vez.

Definición 3.12 (Cuantiles)**.** Para $0 < \gamma < 1$ y ν grados de libertad, $t_{\gamma,\nu}$ y $\chi^2_{\gamma,\nu}$ son los números tales que

$$\mathbb{P}\big(t_\nu \le t_{\gamma,\nu}\big) = \gamma, \qquad \mathbb{P}\big(\chi^2_\nu \le \chi^2_{\gamma,\nu}\big) = \gamma,$$

es decir, γ es el área *a la izquierda* del cuantil. Para la normal estándar se conserva la convención de cola derecha: $\mathbb{P}(Z \ge z_\alpha) = \alpha$, de modo que z_α es el cuantil de orden $1-\alpha$ (por ejemplo $z_{0,025} = 1{,}960$).

Proposición 3.13 (Simetría de la t)**.** *Para todo $\gamma \in (0,1)$ se tiene $t_{1-\gamma,\nu} = -t_{\gamma,\nu}$. En particular $t_{\alpha,\nu} = -t_{1-\alpha,\nu}$.*

Solución. La densidad de t_ν es par, así que $\mathbb{P}(t_\nu \le -c) = \mathbb{P}(t_\nu \ge c) = 1 - \mathbb{P}(t_\nu \le c)$ para todo c. Con $c = t_{\gamma,\nu}$ queda $\mathbb{P}(t_\nu \le -t_{\gamma,\nu}) = 1-\gamma$, que es la definición de $t_{1-\gamma,\nu}$.

La chi-cuadrada no es simétrica (vive en $[0,\infty)$ y tiene cola derecha larga), así que un intervalo o una prueba bilateral necesitan *dos* cuantiles que hay que buscar por separado: $\chi^2_{\alpha/2,\nu}$ y $\chi^2_{1-\alpha/2,\nu}$. Ninguno se obtiene del otro cambiando el signo.

Receta en tres pasos.

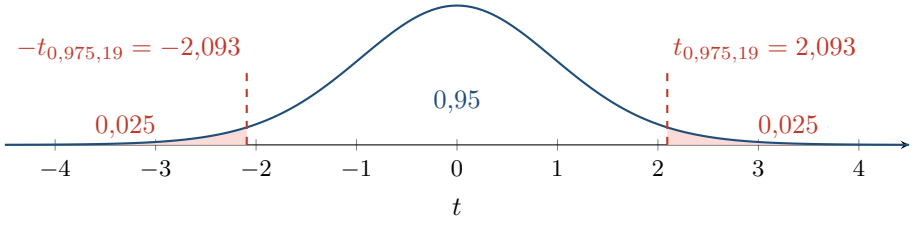
(1) *Grados de libertad.* $\nu = n-1$ para una muestra (media con S, varianza, diferencias pareadas); $\nu = n_1 + n_2 - 2$ para dos muestras con varianza común; $\nu = n-2$ en regresión simple.

(2) *Del nivel al área.* Con nivel α:

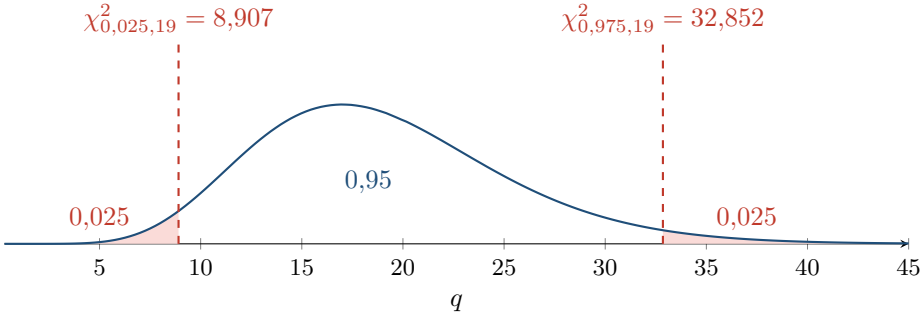
Alternativa	frontera t	frontera(s) χ^2
bilateral ($\neq$)	$\pm t_{1-\alpha/2,\nu}$	$\chi^2_{\alpha/2,\nu}$ y $\chi^2_{1-\alpha/2,\nu}$
cola derecha ($>$)	$t_{1-\alpha,\nu}$	$\chi^2_{1-\alpha,\nu}$
cola izquierda ($<$)	$t_{\alpha,\nu} = -t_{1-\alpha,\nu}$	$\chi^2_{\alpha,\nu}$

(3) *Leer la tabla.* Fila ν, columna γ. Cuidado: muchas tablas encabezan las columnas con el área de la cola *derecha* $1-\gamma$. Una prueba rápida de qué convención usa una tabla: en la t, la columna de 1,960 en la fila $\nu = \infty$ es la de $\gamma = 0{,}975$ (cola derecha 0,025).

t_{19}: área central 0,95



χ^2_{19}: dos cuantiles distintos



Explicación de las figuras. En la t_{19} las dos colas de área 0,025 son imágenes en espejo, así que basta un número, 2,093. En la χ^2_{19} las colas tienen la misma área pero fronteras muy distintas, 8,907 y 32,852, y el centro de masa (media 19) no está a la mitad entre ellas.

	$\gamma = \mathbb{P}(t_\nu \leq t_{\gamma,\nu})$				
ν	0,90	0,95	0,975	0,99	0,995
1	3.078	6.314	12.706	31.821	63.657
2	1.886	2.920	4.303	6.965	9.925
3	1.638	2.353	3.182	4.541	5.841
4	1.533	2.132	2.776	3.747	4.604
5	1.476	2.015	2.571	3.365	4.032
6	1.440	1.943	2.447	3.143	3.707
7	1.415	1.895	2.365	2.998	3.499
8	1.397	1.860	2.306	2.896	3.355
9	1.383	1.833	2.262	2.821	3.250
10	1.372	1.812	2.228	2.764	3.169
12	1.356	1.782	2.179	2.681	3.055
15	1.341	1.753	2.131	2.602	2.947
19	1.328	1.729	2.093	2.539	2.861
20	1.325	1.725	2.086	2.528	2.845
29	1.311	1.699	2.045	2.462	2.756
30	1.310	1.697	2.042	2.457	2.750
40	1.303	1.684	2.021	2.423	2.704
60	1.296	1.671	2.000	2.390	2.660
120	1.289	1.658	1.980	2.358	2.617
∞	1.282	1.645	1.960	2.326	2.576

Tabla 1: Cuantiles $t_{\gamma,\nu}$ de la t de Student. La fila ∞ es la normal estándar: $t_{0{,}975,\infty} = z_{0{,}025} = 1{,}960$.

	$\gamma = \mathbb{P}(\chi^2_\nu \le \chi^2_{\gamma,\nu})$					
ν	0,005	0,025	0,05	0,95	0,975	0,995
1	0.00004	0.00098	0.00393	3.841	5.024	7.879
2	0.010	0.051	0.103	5.991	7.378	10.597
3	0.072	0.216	0.352	7.815	9.348	12.838
4	0.207	0.484	0.711	9.488	11.143	14.860
5	0.412	0.831	1.145	11.070	12.833	16.750
6	0.676	1.237	1.635	12.592	14.449	18.548
7	0.989	1.690	2.167	14.067	16.013	20.278
8	1.344	2.180	2.733	15.507	17.535	21.955
9	1.735	2.700	3.325	16.919	19.023	23.589
10	2.156	3.247	3.940	18.307	20.483	25.188
12	3.074	4.404	5.226	21.026	23.337	28.300
15	4.601	6.262	7.261	24.996	27.488	32.801
19	6.844	8.907	10.117	30.144	32.852	38.582
20	7.434	9.591	10.851	31.410	34.170	39.997
29	13.121	16.047	17.708	42.557	45.722	52.336
30	13.787	16.791	18.493	43.773	46.979	53.672
40	20.707	24.433	26.509	55.758	59.342	66.766
50	27.991	32.357	34.764	67.505	71.420	79.490
60	35.534	40.482	43.188	79.082	83.298	91.952

Tabla 2: Cuantiles $\chi^2_{\gamma,\nu}$ de la chi-cuadrada. Las tres columnas de la izquierda dan fronteras de cola izquierda; las tres de la derecha, de cola derecha.

Ejemplo 3.14 (Lectura directa)**.** (a) Prueba t bilateral, $n = 20$, $\alpha = 0{,}05$: $\nu = 19$, $\gamma = 0{,}975$, frontera $\pm t_{0{,}975,19} = \pm 2{,}093$.

(b) Prueba t de cola izquierda, $n = 16$, $\alpha = 0{,}05$: $\nu = 15$, frontera $t_{0{,}05,15} = -t_{0{,}95,15} = -1{,}753$.

(c) Prueba χ^2 bilateral para σ^2, $n = 20$, $\alpha = 0{,}05$: $\nu = 19$, fronteras $\chi^2_{0{,}025,19} = 8{,}907$ y $\chi^2_{0{,}975,19} = 32{,}852$.

(d) Prueba χ^2 de cola derecha, $n = 30$, $\alpha = 0{,}05$: $\nu = 29$, frontera $\chi^2_{0{,}95,29} = 42{,}557$.

(e) IC del 99 % para μ con $n = 11$: $\nu = 10$, $\gamma = 0{,}995$, $t_{0{,}995,10} = 3{,}169$.

Grados de libertad que no están en la tabla. Los cuantiles $t_{\gamma,\nu}$ y $\chi^2_{\gamma,\nu}/\nu$ son casi lineales en $1/\nu$, así que se interpola en $1/\nu$ y no en ν.

Ejemplo 3.15 (Interpolación)**.** Para $t_{0{,}975,24}$ la tabla da $t_{0{,}975,20} = 2{,}086$ y $t_{0{,}975,30} = 2{,}042$. Como

$$\frac{1/20 - 1/24}{1/20 - 1/30} = \frac{1/120}{1/60} = \frac{1}{2},$$

se toma el punto medio: $t_{0{,}975,24} \approx 2{,}064$ (valor exacto 2,0639; la interpolación lineal en ν daría 2,068). Del mismo modo, entre $\nu = 40$ (1,684) y $\nu = 60$ (1,671),

$$t_{0{,}95,59} \approx 1{,}684 + (1{,}671 - 1{,}684)\,\frac{1/40 - 1/59}{1/40 - 1/60} \approx 1{,}671.$$

Muchos grados de libertad.

Proposición 3.16 (Límites de los cuantiles)**.** *(i)* $t_{\gamma,\nu} \to z_{1-\gamma}$ *cuando* $\nu \to \infty$ *(el cuantil normal de orden* γ*).*

(ii) $\big(\chi^2_{\gamma,\nu} - \nu\big)/\sqrt{2\nu} \to z_{1-\gamma}$ *cuando* $\nu \to \infty$*, es decir* $\chi^2_{\gamma,\nu} \approx \nu + z_{1-\gamma}\sqrt{2\nu}$*.*

Solución. (ii) Si $U_\nu \sim \chi^2_\nu$, entonces $U_\nu = \sum_{i=1}^{\nu} Z_i^2$ con $\mathbb{E}Z_i^2 = 1$ y $\mathrm{Var}Z_i^2 = 2$, y por el TCL $(U_\nu - \nu)/\sqrt{2\nu} \Rightarrow N(0,1)$. Como la función de distribución límite es continua y estrictamente creciente, los cuantiles convergen a los cuantiles del límite. (i) Si $T_\nu = Z/\sqrt{U_\nu/\nu}$, la ley de los grandes números da $U_\nu/\nu \to 1$ en probabilidad, y por Slutsky $T_\nu \Rightarrow N(0,1)$; se concluye como en (ii).

Observación 3.17 (Wilson–Hilferty). La aproximación (ii) es burda en la cola: para $\nu = 60$, $\gamma = 0{,}95$ da 78,02 contra el valor exacto 79,08. Mucho mejor es aproximar $(\chi^2_\nu/\nu)^{1/3}$ por una normal con media $1 - \frac{2}{9\nu}$ y varianza $\frac{2}{9\nu}$:

$$\chi^2_{\gamma,\nu} \approx \nu \left(1 - \frac{2}{9\nu} + z_{1-\gamma}\sqrt{\frac{2}{9\nu}}\right)^3.$$

Con $\nu = 29$, $\gamma = 0{,}95$ ($z_{0{,}05} = 1{,}645$) da 42,55 (exacto 42,557); con $\nu = 19$, $\gamma = 0{,}025$ da 8,89 (exacto 8,907).

Observación 3.18 (Con hoja de cálculo o lenguaje estadístico). Las mismas cantidades se obtienen sin tabla:

Cantidad	Excel (inglés)	Excel (español)	R	Python (`scipy.stats`)
$t_{\gamma,\nu}$	`T.INV(`γ`,`ν`)`	`INV.T(`γ`;`ν`)`	`qt(`γ`,`ν`)`	`t.ppf(`γ`,`ν`)`
$\chi^2_{\gamma,\nu}$	`CHISQ.INV(`γ`,`ν`)`	`INV.CHICUAD(`γ`;`ν`)`	`qchisq(`γ`,`ν`)`	`chi2.ppf(`γ`,`ν`)`
z de orden γ	`NORM.S.INV(`γ`)`	`INV.NORM.ESTAND(`γ`)`	`qnorm(`γ`)`	`norm.ppf(`γ`)`
$\mathbb{P}(t_\nu \ge t)$	`T.DIST.RT(`t`,`ν`)`	`DISTR.T.CD(`t`;`ν`)`	`1-pt(`t`,`ν`)`	`t.sf(`t`,`ν`)`
$\mathbb{P}(\chi^2_\nu \ge q)$	`CHISQ.DIST.RT(`q`,`ν`)`	`DISTR.CHICUAD.CD(`q`;`ν`)`	`1-pchisq(`q`,`ν`)`	`chi2.sf(`q`,`ν`)`

Por ejemplo, `T.INV(0.975,19)` devuelve 2,093 y `CHISQ.INV(0.025,19)` devuelve 8,907.

3.5. Ejemplos resueltos de IC

Ejemplo 3.19 (IC para media de retornos (finanzas))**.** Con retornos $R_1, \ldots, R_n$ y suponer normalidad, un IC 95 % para μ es

$$\overline{X} \pm t_{0{,}975,n-1}\frac{S}{\sqrt{n}}.$$

Solución. Si $R_1, \ldots, R_n \sim N(\mu, \sigma^2)$ i.i.d. y σ es desconocida, el pivote exacto es

$$T = \frac{\overline{R} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

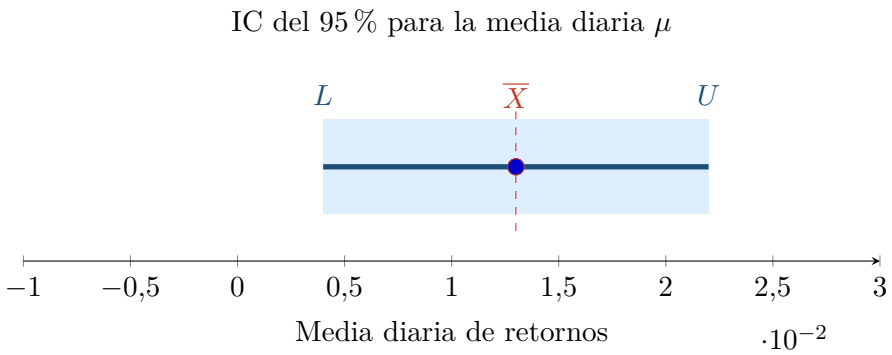
Para 95 % de confianza tomamos $\alpha = 0{,}05$ y por tanto

$$\mathbb{P}\left(-t_{0{,}975,n-1} \le \frac{\overline{R} - \mu}{S/\sqrt{n}} \le t_{0{,}975,n-1}\right) = 0{,}95.$$

Despejando μ se obtiene

$$\mu \in \left[\overline{R} - t_{0,975,n-1}\frac{S}{\sqrt{n}},\ \overline{R} + t_{0,975,n-1}\frac{S}{\sqrt{n}}\right].$$

Interpretación business: este intervalo entrega el rango de valores plausibles para el rendimiento medio diario de la estrategia o del activo. Si todo el intervalo estuviera por arriba de 0, tendríamos evidencia de rentabilidad media positiva; si contiene al 0, la evidencia es débil o ambigua.



Explicación de la figura. La franja azul representa el conjunto de valores plausibles para la media poblacional μ al 95 %. El punto rojo es la media muestral $\overline{X}$, que funciona como centro del intervalo. Cuanto más corto es el segmento azul, mayor es la precisión de la estimación.

Ejemplo 3.20 (IC para volatilidad (finanzas))**.** Bajo normalidad, un IC 95 % para σ^2 es el de Teorema 3.9 con $\alpha = 0{,}05$. Para σ toma raíz cuadrada; para anualizar multiplica por $\sqrt{252}$.

Solución. Bajo normalidad, el pivote

$$Q = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$$

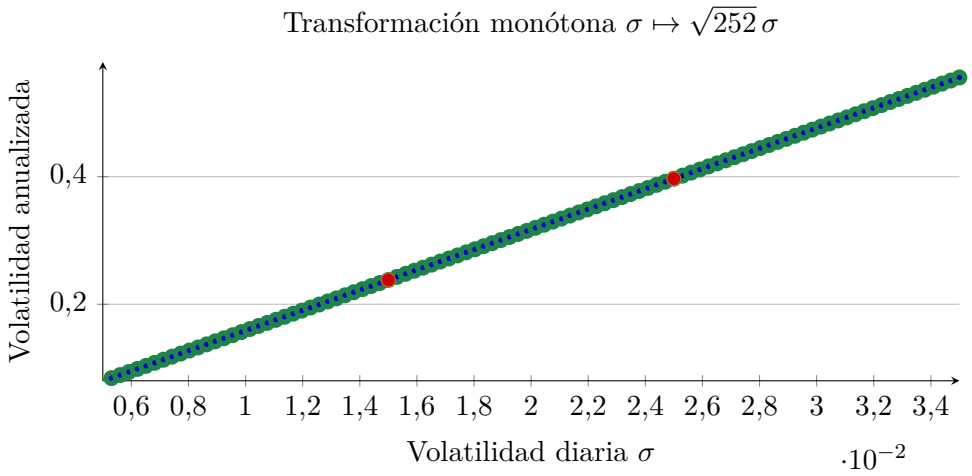
permite construir primero un IC exacto para σ^2:

$$\sigma^2 \in \left[\frac{(n-1)S^2}{\chi^2_{0,975,n-1}},\ \frac{(n-1)S^2}{\chi^2_{0,025,n-1}}\right].$$

Luego aplicamos dos transformaciones económicas muy naturales:

$$\sigma = \sqrt{\sigma^2}, \qquad \sigma_{\text{anual}} = \sqrt{252}\,\sigma.$$

Como tanto la raíz cuadrada como la multiplicación por $\sqrt{252}$ son transformaciones monótonas crecientes, basta transformar extremo inferior y extremo superior. En términos financieros, este ejemplo muestra cómo pasar de incertidumbre en la varianza diaria a incertidumbre en una medida mucho más interpretable para gestión de riesgo: la volatilidad anualizada.



Explicación de la figura. La recta verde muestra que anualizar volatilidad es una transformación lineal creciente. Si un valor diario es plausible, su versión anualizada también lo es al transformar ambos extremos del intervalo. Los puntos naranjas ilustran cómo cambian dos niveles diarios típicos al pasar a escala anual.

Ejemplo 3.21 (IC aproximado para proporción de días positivos)**.** Con $X_i = \mathbb{1}_{\{R_i>0\}}$ y n grande, un IC aproximado $1-\alpha$ para p es

$$\overline{X} \pm z_{\alpha/2}\sqrt{\frac{\overline{X}(1-\overline{X})}{n}}.$$

Solución. Como $X_i = \mathbf{1}_{\{R_i>0\}}$, tenemos $X_i \sim \text{Bernoulli}(p)$ y

$$\mathbb{E}[X_i] = p, \qquad \text{Var}(X_i) = p(1-p).$$

Entonces

$$\overline{X} = \widehat{p}, \qquad \text{Var}(\widehat{p}) \approx \frac{p(1-p)}{n}.$$

Para n grande, el CLT da

$$\frac{\widehat{p}-p}{\sqrt{p(1-p)/n}} \approx N(0,1).$$

Como p es desconocido, sustituimos p por $\widehat{p} = \overline{X}$, obteniendo el IC Wald

$$\widehat{p} \pm z_{\alpha/2}\sqrt{\frac{\widehat{p}(1-\widehat{p})}{n}}.$$

Interpretación de negocio: el intervalo cuantifica la incertidumbre en la fracción de días "ganadores" de una estrategia. No basta decir que el porcentaje observado fue alto; hay que medir cuán estable podría ser ese porcentaje en la población.

Ejemplo 3.22 (Tamaño muestral para margen de error del spread medio)**.** Si el spread diario S_i tiene desviación típica aproximada $\sigma \approx 0{,}8$ centavos y deseas margen $E = 0{,}2$ centavos con 95 % de confianza usando aproximación normal, toma

$$n \geq \left(\frac{1{,}96 \cdot 0{,}8}{0{,}2}\right)^2 = (7{,}84)^2 \approx 61{,}47,$$

así que $n = 62$ días.

Solución. La fórmula general para controlar un margen de error E en un IC normal para la media es

$$n \geq \left(\frac{z_{\alpha/2}\sigma}{E}\right)^2.$$

Aquí el problema es operacional: ¿cuántos días de datos necesito para estimar el spread promedio con precisión útil para trading o microestructura? Sustituyendo $z_{0,025} = 1{,}96$, $\sigma = 0{,}8$ y $E = 0{,}2$ obtenemos

$$n \geq \left(\frac{1{,}96 \cdot 0{,}8}{0{,}2}\right)^2 \approx 61{,}47.$$

Como el tamaño de muestra debe ser entero y además queremos garantizar el margen deseado, redondeamos hacia arriba: $n = 62$.

4. Pruebas de hipótesis: nivel, potencia, p-value; razón de verosimilitud

4.1. Definiciones básicas

Definición 4.1 (Prueba, región crítica, nivel)**.** Una prueba es una función $\varphi(X) \in \{0, 1\}$: *rechaza* H_0 si $\varphi = 1$. Su *nivel* es $\sup_{\theta \in \Theta_0} \mathbb{E}_\theta[\varphi] \leq \alpha$ (control de error tipo I).

Definición 4.2 (Errores tipo I/II; potencia)**.** Error tipo I: rechazar H_0 siendo cierta (probabilidad $\leq \alpha$). Error tipo II: no rechazar H_0 siendo falsa (probabilidad $\beta(\theta)$). Potencia: $1 - \beta(\theta)$.

Definición 4.3 (p-value (forma estándar))**.** Dado estadístico W y valor observado w_{obs}, el p-value es $\mathbb{P}_{H_0}(\text{“tan extremo o más” que } w_{\text{obs}})$ en la dirección de H_1.

4.2. Neyman–Pearson (hipótesis simples) con prueba completa

Teorema 4.4 (Neyman–Pearson (simples))**.** *Para $H_0 : f_0$ vs $H_1 : f_1$, la prueba de razón de verosimilitudes*

$$\varphi^*(x) = \mathbf{1}_{\{\Lambda(x) \leq c\}}, \qquad \Lambda(x) = \frac{f_0(x)}{f_1(x)},$$

con c elegido de modo que

$$\mathbb{E}_0[\varphi^*] = \alpha \quad (o \ \leq \alpha)$$

es la prueba más poderosa de nivel α.

Solución. Sea φ cualquier prueba tal que $\mathbb{E}_0[\varphi] \leq \alpha$. Entonces

$$\mathbb{E}_1[\varphi^* - \varphi] = \int (\varphi^* - \varphi) f_1(x)\, \mathrm{d}x = \int (\varphi^* - \varphi) \frac{f_1(x)}{f_0(x)} f_0(x)\, \mathrm{d}x.$$

En el conjunto $\{\varphi^* = 1\}$ se tiene $f_1/f_0 \geq 1/c$ (equivalentemente $\Lambda \leq c$); en $\{\varphi^* = 0\}$ se tiene $f_1/f_0 \leq 1/c$.

Por tanto,

$$\mathbb{E}_1[\varphi^* - \varphi] \geq \frac{1}{c} \int (\varphi^* - \varphi) f_0(x)\, \mathrm{d}x = \frac{1}{c}\big(\mathbb{E}_0[\varphi^*] - \mathbb{E}_0[\varphi]\big) \geq 0.$$

En consecuencia,

$$\mathbb{E}_1[\varphi^*] \geq \mathbb{E}_1[\varphi].$$

4.3. Pruebas para media: z y t; dualidad IC–prueba

Teorema 4.5 (z-test para media con σ conocida)**.** *Si $X_i \sim N(\mu, \sigma^2)$ i.i.d. con σ conocida, para $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$,*

$$W = \frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0,1) \text{ bajo } H_0,$$

y la prueba de nivel α rechaza si $|W| \geq z_{\alpha/2}$.

Solución. Bajo H_0, $\overline{X} \sim N(\mu_0, \sigma^2/n)$; al estandarizar se obtiene $N(0,1)$. La región $\{|W| \geq z_{\alpha/2}\}$ tiene probabilidad α por definición del cuantil.

Teorema 4.6 (t-test para media con σ desconocida (normal))**.** *Si $X_i \sim N(\mu, \sigma^2)$ i.i.d. con σ desconocida, para $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$,*

$$T = \frac{\overline{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1} \text{ bajo } H_0,$$

y se rechaza si $|T| \geq t_{1-\alpha/2,n-1}$.

Solución. Es Teorema 3.10 con μ reemplazada por μ_0.

Proposición 4.7 (Dualidad IC–prueba)**.** *En normal con σ desconocida: el t-test bilateral de nivel α no rechaza $H_0 : \mu = \mu_0$ si y sólo si μ_0 pertenece al IC $1-\alpha$ de Teorema 3.11.*

Solución. No rechazar equivale a $|T| < t_{1-\alpha/2,n-1}$, es decir

$$\left|\frac{\overline{X} - \mu_0}{S/\sqrt{n}}\right| < t_{1-\alpha/2,n-1} \iff \overline{X} - t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}} < \mu_0 < \overline{X} + t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}}.$$

Esto es exactamente "μ_0 cae dentro del IC".

4.4. Pruebas para dos muestras y para varianzas

Definición 4.8 (Distribución F)**.** Si $U \sim \chi^2_{d_1}$ y $V \sim \chi^2_{d_2}$ son independientes, $\dfrac{U/d_1}{V/d_2} \sim F_{d_1,d_2}$. Su cuantil F_{γ,d_1,d_2} cumple $\mathbb{P}(F_{d_1,d_2} \leq F_{\gamma,d_1,d_2}) = \gamma$.

Proposición 4.9 (Pivotes de dos muestras)**.** *Sean $X_1, \ldots, X_{n_1} \sim N(\mu_1, \sigma_1^2)$ y $Y_1, \ldots, Y_{n_2} \sim N(\mu_2, \sigma_2^2)$ muestras independientes, con varianzas muestrales S_1^2, S_2^2.*

(a) Si $\sigma_1 = \sigma_2$, con $S_p^2 = \dfrac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$,

$$T = \frac{(\overline{X} - \overline{Y}) - (\mu_1 - \mu_2)}{S_p\sqrt{1/n_1 + 1/n_2}} \sim t_{n_1+n_2-2}.$$

(b) $\dfrac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1,\,n_2-1}$, *y* $F_{\gamma,d_1,d_2} = 1/F_{1-\gamma,d_2,d_1}$.

(c) *Si los datos vienen en pares* (X_i, Y_i) *y* $D_i = X_i - Y_i \sim N(\mu_D, \sigma_D^2)$ *i.i.d., entonces* $(\overline{D} - \mu_D)/(S_D/\sqrt{n}) \sim t_{n-1}$.

Solución. (a) Con $\sigma = \sigma_1 = \sigma_2$, $\overline{X} - \overline{Y} \sim N\big(\mu_1 - \mu_2, \sigma^2(1/n_1 + 1/n_2)\big)$, de modo que $Z = \dfrac{(\overline{X} - \overline{Y}) - (\mu_1 - \mu_2)}{\sigma\sqrt{1/n_1 + 1/n_2}} \sim N(0,1)$. Además $(n_1 - 1)S_1^2/\sigma^2 \sim \chi^2_{n_1-1}$ y $(n_2 - 1)S_2^2/\sigma^2 \sim \chi^2_{n_2-1}$ son independientes (vienen de muestras independientes), luego su suma $U = (n_1 + n_2 - 2)S_p^2/\sigma^2 \sim \chi^2_{n_1+n_2-2}$. Dentro de cada muestra la media es independiente de la varianza muestral, así que Z y U son independientes, y $T = Z/\sqrt{U/(n_1 + n_2 - 2)}$ es $t_{n_1+n_2-2}$ por definición.

(b) $U = (n_1 - 1)S_1^2/\sigma_1^2$ y $V = (n_2 - 1)S_2^2/\sigma_2^2$ son chi-cuadradas independientes con $n_1 - 1$ y $n_2 - 1$ grados; el cociente del enunciado es $\frac{U/(n_1-1)}{V/(n_2-1)}$. Si $W \sim F_{d_1,d_2}$ entonces $1/W \sim F_{d_2,d_1}$, y $\mathbb{P}(W \le 1/c) = \mathbb{P}(1/W \ge c)$; tomando $c = F_{1-\gamma,d_2,d_1}$ se obtiene $\mathbb{P}(W \le 1/c) = \gamma$.

(c) Es el pivote t de una muestra aplicado a $D_1, \ldots, D_n$.

Observación 4.10 (Proporciones). Si $\widehat{p}$ es la proporción de éxitos en n ensayos de Bernoulli(p), el TCL da $(\widehat{p} - p)/\sqrt{p(1-p)/n} \Rightarrow N(0,1)$. Para dos muestras independientes, bajo $H_0 : p_1 = p_2$ se estima la p común por $\widehat{p} = (x_1 + x_2)/(n_1 + n_2)$ y, por Slutsky,

$$\frac{\widehat{p}_1 - \widehat{p}_2}{\sqrt{\widehat{p}(1-\widehat{p})(1/n_1 + 1/n_2)}} \Rightarrow N(0,1).$$

La regla práctica para usar la aproximación es tener al menos 5 éxitos y 5 fracasos esperados en cada muestra.

4.5. Tabla de pruebas de hipótesis

La Tabla 3 reúne los estadísticos y la Tabla 4 las regiones de rechazo y los p-values. En cada caso θ_0 es el valor de frontera de H_0.

Parámetro	**Supuestos**	**Estadístico**	**Ley bajo H_0**
μ	normal, o n grande; σ conocida	$Z = \dfrac{\overline{X} - \mu_0}{\sigma/\sqrt{n}}$	$N(0,1)$
μ	normal; σ desconocida	$T = \dfrac{\overline{X} - \mu_0}{S/\sqrt{n}}$	t_{n-1}
μ_D (pareadas)	diferencias normales	$T = \dfrac{\overline{D} - \delta_0}{S_D/\sqrt{n}}$	t_{n-1}
p	$np_0 \geq 5$, $n(1-p_0) \geq 5$	$Z = \dfrac{\widehat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$	$\approx N(0,1)$
σ^2	normal	$Q = \dfrac{(n-1)S^2}{\sigma_0^2}$	χ^2_{n-1}
$\mu_1 - \mu_2$	normales independientes; σ_1, σ_2 conocidas	$Z = \dfrac{\overline{X} - \overline{Y} - \delta_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$	$N(0,1)$
$\mu_1 - \mu_2$	normales independientes; $\sigma_1 = \sigma_2$ desconocida	$T = \dfrac{\overline{X} - \overline{Y} - \delta_0}{S_p\sqrt{1/n_1 + 1/n_2}}$	$t_{n_1+n_2-2}$
$p_1 - p_2$	muestras grandes independientes	$Z = \dfrac{\widehat{p}_1 - \widehat{p}_2}{\sqrt{\widehat{p}(1-\widehat{p})(1/n_1 + 1/n_2)}}$	$\approx N(0,1)$
σ_1^2/σ_2^2	normales independientes	$F = \dfrac{S_1^2}{S_2^2}$	$F_{n_1-1,\, n_2-1}$
β_1 (regresión)	modelo lineal normal	$T = \dfrac{\widehat{\beta}_1 - b_0}{\widehat{\mathrm{se}}(\widehat{\beta}_1)}$	t_{n-2}

Tabla 3: Pruebas de hipótesis clásicas. S_p^2 es la varianza combinada de la Proposición 4.9 y $\widehat{p} = (x_1 + x_2)/(n_1 + n_2)$.

	Estadístico Z	Estadístico T (ν)	Estadístico $Q \sim \chi^2_\nu$ o F
$H_1 : \theta \neq \theta_0$	$\lvert z\rvert \geq z_{\alpha/2}$	$\lvert t\rvert \geq t_{1-\alpha/2,\nu}$	$q \leq \chi^2_{\alpha/2,\nu}$ o $q \geq \chi^2_{1-\alpha/2,\nu}$
$H_1 : \theta > \theta_0$	$z \geq z_\alpha$	$t \geq t_{1-\alpha,\nu}$	$q \geq \chi^2_{1-\alpha,\nu}$
$H_1 : \theta < \theta_0$	$z \leq -z_\alpha$	$t \leq -t_{1-\alpha,\nu}$	$q \leq \chi^2_{\alpha,\nu}$
p-value ($\neq$)	$2\,\mathbb{P}(Z \geq \lvert z\rvert)$	$2\,\mathbb{P}(t_\nu \geq \lvert t\rvert)$	$2\,\min\{\mathbb{P}(\chi^2_\nu \leq q), \mathbb{P}(\chi^2_\nu \geq q)\}$
p-value ($>$)	$\mathbb{P}(Z \geq z)$	$\mathbb{P}(t_\nu \geq t)$	$\mathbb{P}(\chi^2_\nu \geq q)$
p-value ($<$)	$\mathbb{P}(Z \leq z)$	$\mathbb{P}(t_\nu \leq t)$	$\mathbb{P}(\chi^2_\nu \leq q)$

Tabla 4: Regiones de rechazo de nivel α y p-values. Para F se usan las mismas reglas que para χ^2 con los cuantiles F_{γ,d_1,d_2}. Se rechaza H_0 exactamente cuando p-value $\leq \alpha$.

4.6. Ejemplos resueltos de pruebas

Ejemplo 4.11 (Retorno medio positivo (finanzas))**.** Datos: $n = 60$, $\overline{X} = 0{,}0005$, $S = 0{,}012$. Prueba $H_0 : \mu \leq 0$ vs $H_1 : \mu > 0$ al 5 %.

Solución. La hipótesis nula relevante para un gestor es conservadora:

$$H_0 : \mu \leq 0 \qquad \text{vs} \qquad H_1 : \mu > 0.$$

La frontera de H_0 es $\mu_0 = 0$, así que usamos el estadístico

$$T = \frac{\overline{X} - \mu_0}{S/\sqrt{n}} = \frac{0{,}0005}{0{,}012/\sqrt{60}} = \frac{0{,}0005\sqrt{60}}{0{,}012} \approx 0{,}3228.$$

Con 59 grados de libertad y nivel $\alpha = 0{,}05$, el valor crítico unilateral es

$$t_{0{,}95,59} \approx 1{,}671.$$

La regla de decisión es:

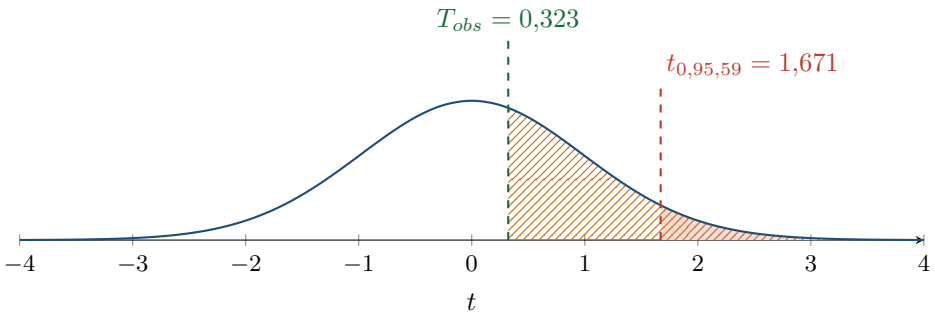
$$\text{rechazar } H_0 \iff T \geq 1{,}671.$$

Como

$$0{,}323 < 1{,}671,$$

el estadístico cae en la región de no rechazo. El p-value es $\mathbb{P}(t_{59} \geq 0{,}323) \approx 0{,}374$, muy lejos de 0,05. Conclusión económica: el rendimiento medio observado es positivo, pero demasiado pequeño respecto a la volatilidad muestral para sostener una afirmación estadística fuerte de "alpha positivo" al 5 %.

Prueba t de cola derecha, $\nu = 59$



Explicación de la figura. La zona roja es la región de rechazo, de área 0,05; la zona rayada es el p-value, el área a la derecha de T_{obs}. El p-value contiene a la región de rechazo y es mucho mayor que 0,05: no se rechaza.

Ejemplo 4.12 (Volatilidad excede límite (finanzas))**.** Supón normalidad, $n = 30$, $S^2 = 0{,}000144$ (var diaria). Probar $H_0 : \sigma^2 \leq 0{,}0001$ vs $H_1 : \sigma^2 > 0{,}0001$ al 5 %.

Solución. La empresa o mesa de riesgo quiere saber si la varianza verdadera rebasa un límite máximo permitido $\sigma_0^2 = 0{,}0001$. La prueba unilateral correcta usa

$$Q = \frac{(n-1)S^2}{\sigma_0^2} = \frac{29 \cdot 0{,}000144}{0{,}0001} = 41{,}76.$$

Bajo la frontera de la nula, $Q \sim \chi^2_{29}$. Como la alternativa es "más volatilidad", la región de rechazo vive en la cola derecha:

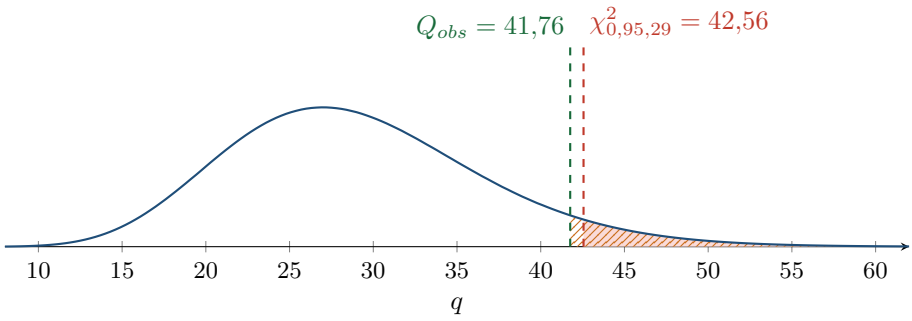
$$\text{rechazar } H_0 \iff Q \geq \chi^2_{0{,}95,29} \approx 42{,}56.$$

Pero

$$41{,}76 < 42{,}56.$$

Por tanto, no se rechaza H_0; el p-value es $\mathbb{P}(\chi^2_{29} \geq 41{,}76) \approx 0{,}059$. La lectura práctica es fina: la volatilidad observada está cerca del límite, así que aunque no hay evidencia suficiente para declarar incumplimiento estadístico al 5 %, sí hay una señal de vigilancia porque el resultado queda muy próximo al umbral crítico.

Prueba χ^2 de cola derecha, $\nu = 29$



Explicación de la figura. La curva es la densidad de χ^2_{29}. La zona roja representa la región de rechazo en la cola derecha: allí caerían valores de volatilidad muestral suficientemente grandes para concluir que el límite fue rebasado. Como $Q_{obs} = 41{,}76$ queda apenas antes del umbral, la evidencia es cercana pero todavía insuficiente al 5 %.

Ejemplo 4.13 (p-value bilateral en t-test)**.** Supón $n = 20$ y $t_{\text{obs}} = 2{,}1$ en una prueba bilateral sobre μ. ¿p-value aproximado?

Solución. Con $n = 20$, los grados de libertad son 19. En una prueba bilateral, el p-value se calcula como

$$p = 2\,\mathbb{P}(t_{19} \geq 2{,}1).$$

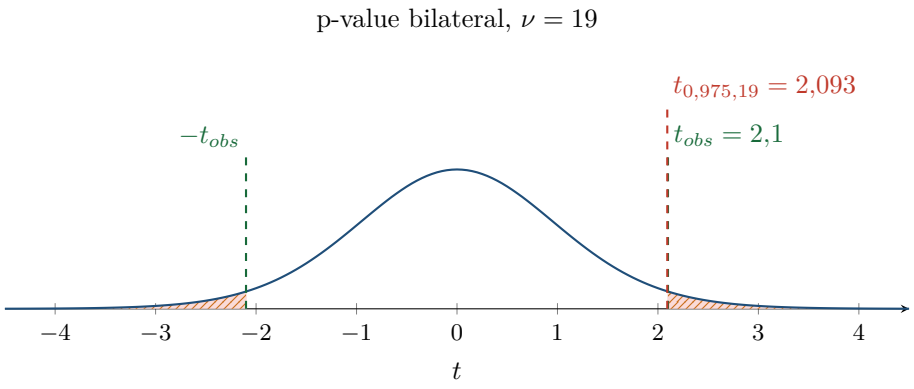
Usando tablas, sabemos que

$$t_{0{,}975,19} \approx 2{,}093.$$

Como el estadístico observado 2,1 está apenas por encima de ese cuantil, el área de cola bilateral es apenas menor que 0,05. Por ello,

$$p \approx 0{,}049\text{–}0{,}050 \qquad \text{(valor exacto } 0{,}0493\text{)}.$$

Interpretación ejecutiva: el resultado es marginalmente significativo. En aplicaciones business, eso sugiere prudencia: una conclusión "significativa" existe, pero no es robusta ni holgada.



Explicación de la figura. El p-value bilateral es la suma de las dos colas rayadas, más allá de $\pm 2{,}1$. Como 2,1 apenas rebasa $t_{0{,}975,19} = 2{,}093$, las colas rayadas son apenas más chicas que las rojas, de área total 0,05.

Ejemplo 4.14 (Proporción de días positivos supera 0.5)**.** En $n = 200$ días, el activo cerró con retorno positivo en 118 días. Probar $H_0 : p \leq 0{,}5$ vs $H_1 : p > 0{,}5$ al 5 % usando aproximación normal.

Solución. Primero calculamos la proporción observada:

$$\widehat{p} = \frac{118}{200} = 0{,}59.$$

Bajo $H_0 : p \leq 0{,}5$, la frontera relevante es $p_0 = 0{,}5$. El estadístico Wald es

$$W = \frac{\widehat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} = \frac{0{,}59 - 0{,}5}{\sqrt{0{,}5 \cdot 0{,}5/200}} \approx 2{,}545.$$

Al 5 % en una cola, el valor crítico normal es

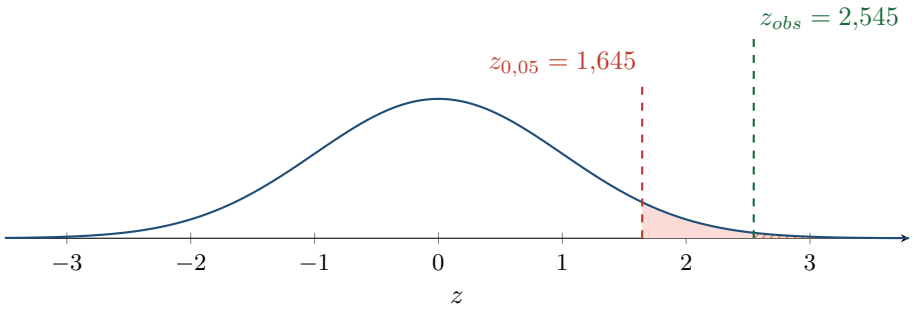
$$z_{0,05} \approx 1{,}645.$$

La regla de decisión es:

$$\text{rechazar } H_0 \iff W \geq 1{,}645.$$

Como $2{,}545 > 1{,}645$, rechazamos H_0; el p-value es $\mathbb{P}(Z \geq 2{,}545) \approx 0{,}0055$. Lectura business: la estrategia tuvo días positivos en una fracción suficientemente alta como para sostener, estadísticamente, que la probabilidad de "ganar el día" supera el 50 %.

Prueba z de cola derecha



Explicación de la figura. Aquí el estadístico observado sí entra en la franja roja. Eso visualiza por qué se rechaza H_0: la proporción observada de días positivos es lo bastante grande como para quedar dentro de la región crítica unilateral.

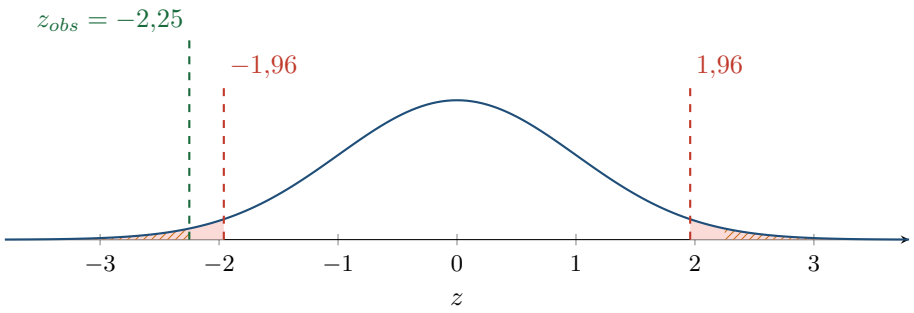
Ejemplo 4.15 (Llenado de botellas: prueba z bilateral)**.** Una máquina llena botellas con contenido nominal de 500 ml; por su historial, $\sigma = 4$ ml. Una muestra de $n = 25$ botellas da $\overline{X} = 498{,}2$. ¿Está descalibrada la máquina? Usa $\alpha = 0{,}05$.

Solución. Se descalibra hacia arriba o hacia abajo, así que la alternativa es bilateral: $H_0 : \mu = 500$ vs $H_1 : \mu \neq 500$. Como σ es conocida,

$$Z = \frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}} = \frac{498{,}2 - 500}{4/5} = \frac{-1{,}8}{0{,}8} = -2{,}25.$$

La frontera es $z_{0,025} = 1{,}96$ y $|Z| = 2{,}25 \geq 1{,}96$: se rechaza H_0. El p-value es $2\,\mathbb{P}(Z \geq 2{,}25) \approx 0{,}0244$. La máquina está llenando de menos y conviene recalibrarla.

Prueba z bilateral, $\alpha = 0{,}05$



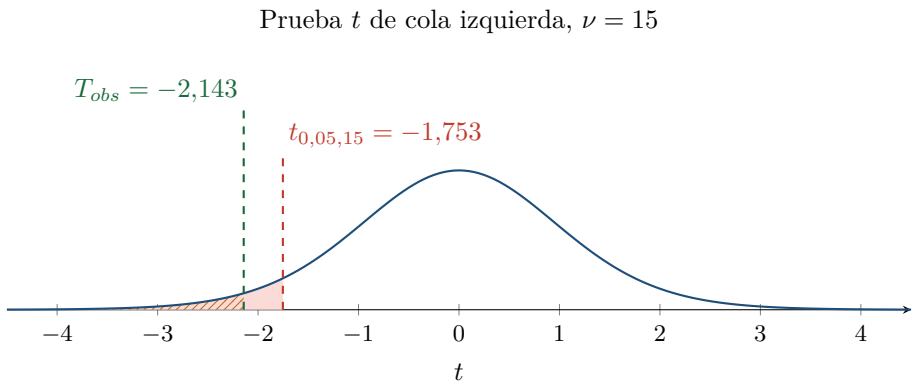
Explicación de la figura. Las dos colas rojas suman 0,05. El estadístico observado cae en la cola izquierda; el p-value (rayado) cuenta también la cola simétrica de la derecha porque la alternativa es bilateral.

Ejemplo 4.16 (Duración de baterías: prueba t de cola izquierda)**.** Un fabricante afirma que sus baterías duran en promedio al menos 40 horas. En $n = 16$ baterías se mide $\overline{X} = 38{,}5$ h y $S = 2{,}8$ h. Suponiendo normalidad, ¿hay evidencia al 5 % contra la afirmación?

Solución. La afirmación del fabricante va en la nula: $H_0 : \mu \geq 40$ vs $H_1 : \mu < 40$. Con σ desconocida,

$$T = \frac{38{,}5 - 40}{2{,}8/\sqrt{16}} = \frac{-1{,}5}{0{,}7} \approx -2{,}143, \qquad \nu = 15.$$

Es una prueba de cola izquierda, así que por la Proposición 3.13 la frontera es $t_{0{,}05,15} = -t_{0{,}95,15} = -1{,}753$ (Tabla 1). Como $-2{,}143 \leq -1{,}753$, se rechaza H_0, con p-value $\mathbb{P}(t_{15} \leq -2{,}143) \approx 0{,}0245$. Los datos contradicen la duración anunciada.



Explicación de la figura. En una alternativa "menor que" la región de rechazo vive a la izquierda. El estadístico cae dentro de ella y el p-value rayado es menor que 0,05.

Ejemplo 4.17 (Datos pareados: presión arterial antes y después)**.** Ocho personas siguen un programa de ejercicio. Su presión sistólica (mmHg) antes y después es:

Persona	1	2	3	4	5	6	7	8
Antes	142	138	150	145	160	155	148	152
Después	136	135	144	146	151	149	145	147
$D =$ antes $-$ después	6	3	6	-1	9	6	3	5

¿Baja la presión media? Usa $\alpha = 0{,}05$.

Solución. Cada persona es su propio control, así que se trabaja con las diferencias D_i (Proposición 4.9(c)): $H_0 : \mu_D \leq 0$ vs $H_1 : \mu_D > 0$. Con los datos,

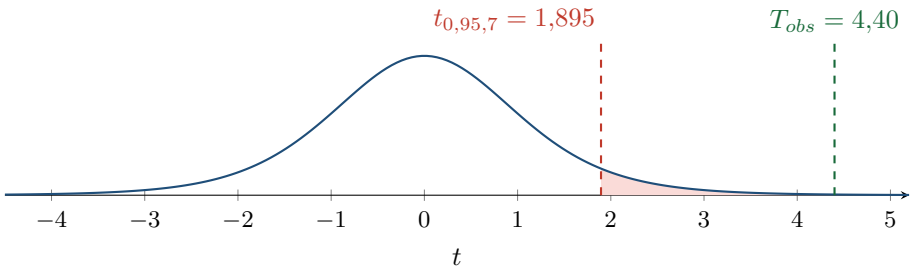
$$\overline{D} = \frac{37}{8} = 4{,}625, \qquad S_D^2 = \frac{1}{7}\sum_{i=1}^{8}(D_i - \overline{D})^2 = \frac{61{,}875}{7} \approx 8{,}839, \qquad S_D \approx 2{,}973,$$

$$T = \frac{\overline{D}}{S_D/\sqrt{8}} = \frac{4{,}625}{1{,}051} \approx 4{,}400, \qquad \nu = 7.$$

La frontera es $t_{0{,}95,7} = 1{,}895$, así que se rechaza H_0 con holgura; el p-value es $\mathbb{P}(t_7 \geq 4{,}400) \approx 0{,}0016$.

Tratar las columnas "antes" y "después" como dos muestras independientes sería un error: la variación entre personas (de 138 a 160) es mucho mayor que el efecto del programa y lo taparía. El emparejamiento elimina esa variación.

Prueba t pareada, $\nu = 7$



Explicación de la figura. El estadístico queda muy dentro de la región de rechazo; el p-value es la diminuta área rayada a su derecha.

Ejemplo 4.18 (Dos grupos: prueba t con varianza combinada)**.** Dos métodos de enseñanza se comparan con un mismo examen. Grupo A: $n_1 = 12$, $\overline{X} = 24{,}6$, $S_1 = 3{,}1$. Grupo B: $n_2 = 10$, $\overline{Y} = 21{,}9$, $S_2 = 2{,}7$. Suponiendo normalidad y varianzas iguales (lo verifica el Ejemplo 4.19), ¿difieren las medias al 5 %?

Solución. $H_0 : \mu_1 = \mu_2$ vs $H_1 : \mu_1 \neq \mu_2$. La varianza combinada es

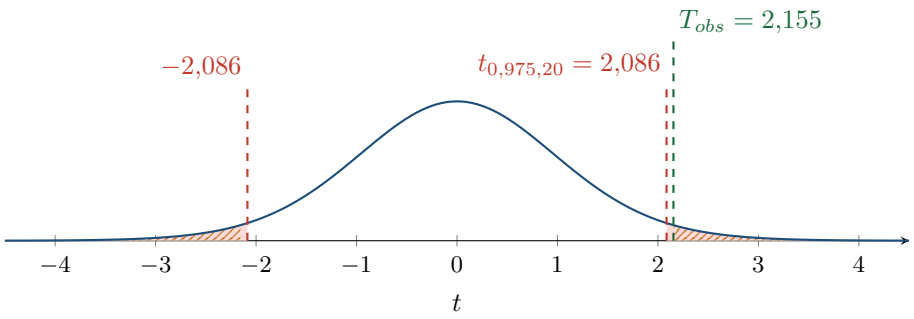
$$S_p^2 = \frac{11 \cdot 3{,}1^2 + 9 \cdot 2{,}7^2}{20} = \frac{105{,}71 + 65{,}61}{20} = 8{,}566, \qquad S_p \approx 2{,}927,$$

y el estadístico

$$T = \frac{24{,}6 - 21{,}9}{2{,}927\sqrt{1/12 + 1/10}} = \frac{2{,}7}{1{,}253} \approx 2{,}155, \qquad \nu = 12 + 10 - 2 = 20.$$

La frontera es $t_{0{,}975,20} = 2{,}086$ y $2{,}155 \geq 2{,}086$: se rechaza H_0, con p-value $2\,\mathbb{P}(t_{20} \geq 2{,}155) \approx 0{,}044$. El método A da mejores resultados, aunque la evidencia no es holgada.

Prueba t de dos muestras, $\nu = 20$



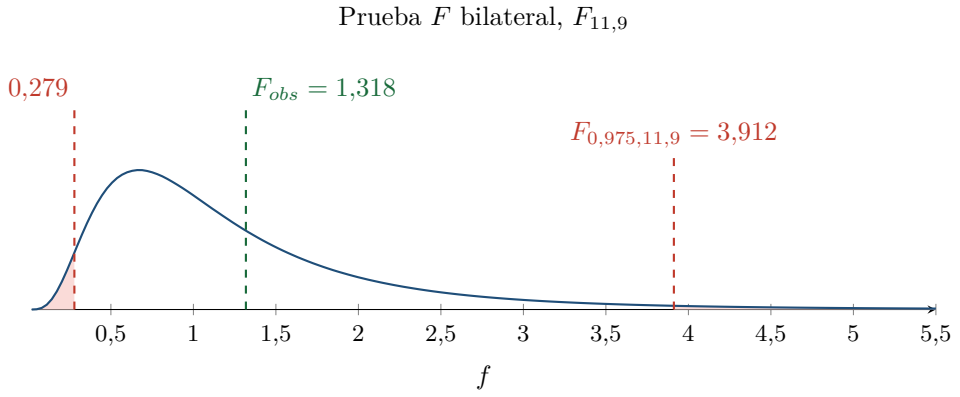
Explicación de la figura. El estadístico apenas rebasa la frontera derecha. El p-value suma las dos colas rayadas y queda poco por debajo de 0,05.

Ejemplo 4.19 (Igualdad de varianzas: prueba F)**.** Con los datos del Ejemplo 4.18, prueba $H_0 : \sigma_1^2 = \sigma_2^2$ vs $H_1 : \sigma_1^2 \neq \sigma_2^2$ al 5 %.

Solución. Por la Proposición 4.9(b), bajo H_0 el cociente $F = S_1^2/S_2^2$ sigue una $F_{11,9}$. Aquí

$$F = \frac{3{,}1^2}{2{,}7^2} = \frac{9{,}61}{7{,}29} \approx 1{,}318.$$

Las fronteras son $F_{0{,}975,11,9} = 3{,}912$ y, con la identidad de reciprocidad, $F_{0{,}025,11,9} = 1/F_{0{,}975,9,11} = 1/3{,}588 = 0{,}279$. Como $0{,}279 < 1{,}318 < 3{,}912$, no se rechaza H_0 (p-value $\approx 0{,}69$): el supuesto de varianzas iguales del ejemplo anterior es razonable.



Explicación de la figura. Como la χ^2, la F es asimétrica: la cola izquierda de área 0,025 termina en 0,279 y la derecha empieza en 3,912. El valor observado cae en la zona central.

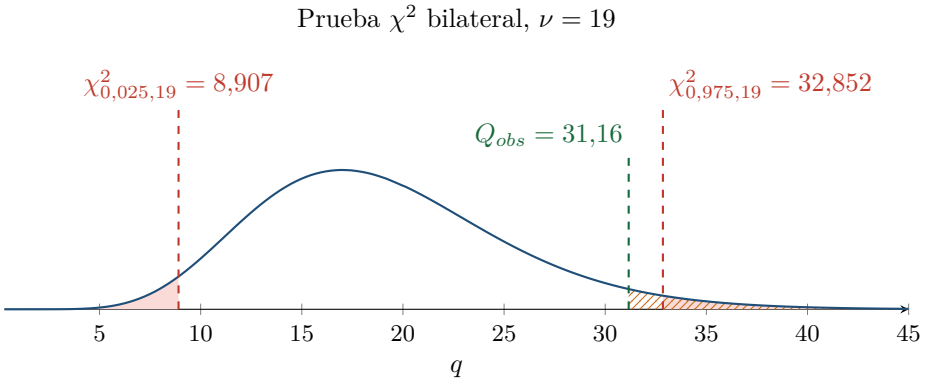
Ejemplo 4.20 (Precisión de una máquina: prueba χ^2 bilateral)**.** Una pieza debe fabricarse con varianza de diámetro $\sigma^2 = 0{,}25$ mm^2. En $n = 20$ piezas se obtiene $S^2 = 0{,}41$. Suponiendo normalidad, ¿difiere la varianza de la especificación al 5 %?

Solución. $H_0 : \sigma^2 = 0{,}25$ vs $H_1 : \sigma^2 \neq 0{,}25$. El estadístico es

$$Q = \frac{(n-1)S^2}{\sigma_0^2} = \frac{19 \cdot 0{,}41}{0{,}25} = 31{,}16, \qquad \nu = 19.$$

Por ser bilateral se buscan dos cuantiles en la Tabla 2: $\chi^2_{0{,}025,19} = 8{,}907$ y $\chi^2_{0{,}975,19} = 32{,}852$. Como $8{,}907 < 31{,}16 < 32{,}852$, no se rechaza H_0. El p-value es $2\,\text{mín}\{\mathbb{P}(\chi^2_{19} \leq 31{,}16), \mathbb{P}(\chi^2_{19} \geq 31{,}16)\} = 2 \cdot 0{,}039 \approx 0{,}078$.

Si la pregunta hubiera sido "¿*excede* la varianza la especificación?" ($H_1 : \sigma^2 > 0{,}25$), la frontera sería $\chi^2_{0{,}95,19} = 30{,}144$ y se rechazaría (p-value $\approx 0{,}039$). La alternativa debe fijarse antes de ver los datos; elegirla después para conseguir significancia invalida el nivel.



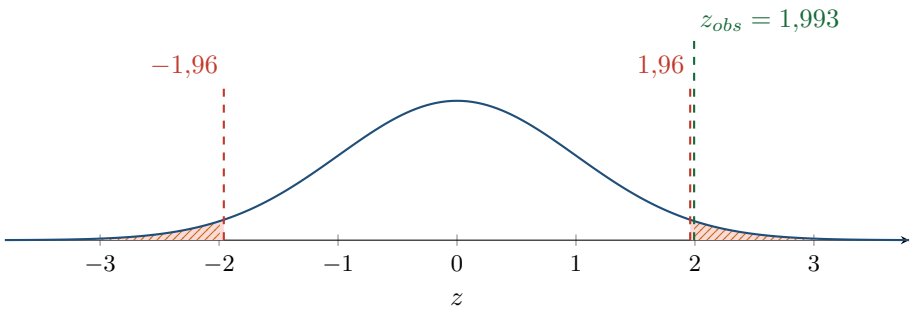
Explicación de la figura. El estadístico queda justo antes de la frontera derecha. El área rayada a su derecha es la mitad del p-value bilateral.

Ejemplo 4.21 (Comparar dos proporciones)**.** Dos versiones de una página web se muestran a 250 visitantes cada una. La versión A logra 46 compras y la B, 30. ¿Difieren las tasas de conversión al 5 %?

Solución. $H_0 : p_1 = p_2$ vs $H_1 : p_1 \neq p_2$. Se tiene $\widehat{p}_1 = 46/250 = 0{,}184$, $\widehat{p}_2 = 30/250 = 0{,}120$ y la proporción combinada $\widehat{p} = 76/500 = 0{,}152$. Entonces

$$Z = \frac{0{,}184 - 0{,}120}{\sqrt{0{,}152 \cdot 0{,}848\,(2/250)}} = \frac{0{,}064}{0{,}0321} \approx 1{,}993.$$

Como $|Z| \geq 1{,}96$, se rechaza H_0, pero por muy poco: el p-value es $2\,\mathbb{P}(Z \geq 1{,}993) \approx 0{,}046$. Con un nivel de 1 % no se rechazaría.



Explicación de la figura. El estadístico observado está prácticamente sobre la frontera: el área rayada es casi igual a la roja.

Ejemplo 4.22 (Potencia y error tipo II)**.** En el Ejemplo 4.15 ($\sigma = 4$, $n = 25$, prueba bilateral al 5 %), ¿con qué probabilidad detecta la prueba una descalibración real a $\mu = 498$? ¿Qué n hace falta para detectarla con probabilidad 0,90?

Solución. Si la media verdadera es μ, el estadístico $Z = (\overline{X} - \mu_0)/(\sigma/\sqrt{n})$ sigue una $N(\delta, 1)$ con $\delta = (\mu - \mu_0)\sqrt{n}/\sigma$, porque $\overline{X} - \mu_0 = (\overline{X} - \mu) + (\mu - \mu_0)$. Por tanto la función de potencia es

$$\pi(\mu) = \mathbb{P}_\mu\big(|Z| \geq z_{\alpha/2}\big) = \Phi\big(-z_{\alpha/2} - \delta\big) + \Phi\big(-z_{\alpha/2} + \delta\big).$$

Con $\mu = 498$: $\delta = (498 - 500) \cdot 5/4 = -2{,}5$ y

$$\pi(498) = \Phi(0{,}54) + \Phi(-4{,}46) \approx 0{,}705 + 0{,}000 = 0{,}705.$$

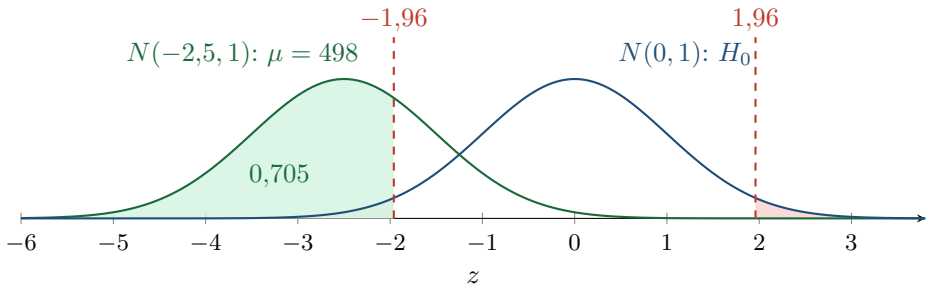
La prueba detecta esa descalibración sólo 70 % de las veces; el error tipo II es $\beta = 0{,}295$.

Para potencia 0,90 se desprecia la cola lejana y se pide $\Phi(-z_{\alpha/2} + |\delta|) \geq 0{,}90$, es decir $|\delta| \geq z_{\alpha/2} + z_{0{,}10}$:

$$n \geq \left(\frac{(z_{0{,}025} + z_{0{,}10})\,\sigma}{|\mu - \mu_0|} \right)^2 = \left(\frac{(1{,}960 + 1{,}282) \cdot 4}{2} \right)^2 \approx 42{,}0,$$

así que bastan $n = 43$ botellas.

Potencia de la prueba z en $\mu = 498$



Explicación de la figura. La curva azul es la ley del estadístico si H_0 es cierta; la verde, si $\mu = 498$. La región de rechazo es la misma para las dos (fronteras $\pm 1{,}96$). Bajo H_0 tiene probabilidad 0,05 (zonas rojas); bajo $\mu = 498$ tiene probabilidad 0,705 (zona verde), que es la potencia.

5. Regresión lineal: mínimos cuadrados, propiedades, inferencia

5.1. Modelo y estimadores OLS

Definición 5.1 (Regresión lineal simple)**.** Dados pares (x_i, y_i) con x_i fijos (o condicionados),

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \qquad \mathbb{E}[\varepsilon_i] = 0, \quad \operatorname{Var}(\varepsilon_i) = \sigma^2,$$

con $\operatorname{Cov}(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$. Para inferencia exacta se suele asumir además $\varepsilon_i \sim N(0, \sigma^2)$ i.i.d.

Define

$$\overline{x} = \frac{1}{n}\sum x_i, \quad \overline{y} = \frac{1}{n}\sum y_i, \quad S_{xx} = \sum (x_i - \overline{x})^2, \quad S_{xy} = \sum (x_i - \overline{x})(y_i - \overline{y}).$$

Teorema 5.2 (Solución OLS)**.** *Si $S_{xx} > 0$, los minimizadores de $\sum (y_i - \beta_0 - \beta_1 x_i)^2$ son*

$$\widehat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \qquad \widehat{\beta}_0 = \overline{y} - \widehat{\beta}_1\,\overline{x}.$$

Solución. Sea $Q(\beta_0,\beta_1)=\sum(y_i-\beta_0-\beta_1x_i)^2$. Deriva e iguala a cero:

$$\frac{\partial Q}{\partial\beta_0}=-2\sum(y_i-\beta_0-\beta_1x_i)=0,\quad \frac{\partial Q}{\partial\beta_1}=-2\sum x_i(y_i-\beta_0-\beta_1x_i)=0.$$

Estas ecuaciones normales equivalen a $\sum e_i=0$ y $\sum x_ie_i=0$. Resolviendo (por álgebra o centrado) se obtiene la fórmula. Unicidad: $S_{xx}>0$.

Lema 5.3 (Propiedades de residuales)**.** *Con $\widehat{y}_i=\widehat{\beta}_0+\widehat{\beta}_1x_i$ y $e_i=y_i-\widehat{y}_i$:*

$$\sum_{i=1}^n e_i=0,\qquad \sum_{i=1}^n x_ie_i=0.$$

Solución. Son exactamente las ecuaciones normales.

5.2. Insesgadez, varianzas y Gauss–Markov (pruebas completas)

Teorema 5.4 (Insesgadez y varianzas de OLS)**.** *Bajo el modelo con $\mathbb{E}[\varepsilon_i]=0$, $\mathrm{Var}(\varepsilon_i)=\sigma^2$ y covarianzas nulas,*

$$\mathbb{E}[\widehat{\beta}_1]=\beta_1,\quad \mathbb{E}[\widehat{\beta}_0]=\beta_0,$$
$$\mathrm{Var}(\widehat{\beta}_1)=\frac{\sigma^2}{S_{xx}},\qquad \mathrm{Var}(\widehat{\beta}_0)=\sigma^2\left(\frac{1}{n}+\frac{\overline{x}^2}{S_{xx}}\right).$$

Solución. Usa $y_i=\beta_0+\beta_1x_i+\varepsilon_i$. Calcula

$$S_{xy}=\sum(x_i-\overline{x})(y_i-\overline{y})=\beta_1S_{xx}+\sum(x_i-\overline{x})\varepsilon_i,$$

pues la parte con β_0 desaparece al centrar. Entonces

$$\widehat{\beta}_1=\frac{S_{xy}}{S_{xx}}=\beta_1+\frac{\sum(x_i-\overline{x})\varepsilon_i}{S_{xx}}.$$

Esperanza: $\mathbb{E}[\widehat{\beta}_1]=\beta_1$. Varianza (covarianzas nulas):

$$\mathrm{Var}(\widehat{\beta}_1)=\frac{1}{S_{xx}^2}\mathrm{Var}\Big(\sum(x_i-\overline{x})\varepsilon_i\Big)=\frac{1}{S_{xx}^2}\sum(x_i-\overline{x})^2\sigma^2=\frac{\sigma^2}{S_{xx}}.$$

Para $\widehat{\beta}_0=\overline{y}-\widehat{\beta}_1\overline{x}$ y $\overline{y}=\beta_0+\beta_1\overline{x}+\overline{\varepsilon}$:

$$\widehat{\beta}_0=\beta_0+\overline{\varepsilon}-\overline{x}(\widehat{\beta}_1-\beta_1).$$

Usa $\mathrm{Var}(\overline{\varepsilon})=\sigma^2/n$ y $\mathrm{Cov}(\overline{\varepsilon},\sum(x_i-\overline{x})\varepsilon_i)=0$ (porque $\sum(x_i-\overline{x})=0$) para obtener $\mathrm{Var}(\widehat{\beta}_0)=\sigma^2(1/n+\overline{x}^2/S_{xx})$.

Teorema 5.5 (Gauss–Markov (BLUE))**.** *Bajo las hipótesis lineales, $\widehat{\beta}_1$ es BLUE: entre estimadores lineales insesgados de β_1, tiene varianza mínima.*

Solución. Sea $\widetilde{\beta}_1=\sum a_iY_i$. Insesgadez impone $\sum a_i=0$ y $\sum a_ix_i=1$. Entonces $\mathrm{Var}(\widetilde{\beta}_1)=\sigma^2\sum a_i^2$. Minimiza $\sum a_i^2$ con multiplicadores: $a_i=\lambda+\mu x_i$. De $\sum a_i=0$ y $\sum a_ix_i=1$ se obtiene

$$a_i=\frac{x_i-\overline{x}}{S_{xx}}.$$

Entonces $\widetilde{\beta}_1=\sum\frac{x_i-\overline{x}}{S_{xx}}Y_i=S_{xy}/S_{xx}=\widehat{\beta}_1$.

5.3. Inferencia exacta bajo normalidad

Proposición 5.6 (Estimador insesgado de σ^2 en regresión)**.** *Con residuales $e_i = y_i - \widehat{y}_i$, define*

$$\widehat{\sigma}^2 = \frac{1}{n-2}\sum_{i=1}^{n} e_i^2.$$

Bajo normalidad de errores, $\mathbb{E}[\widehat{\sigma}^2] = \sigma^2$.

Solución. En el modelo normal, $\sum e_i^2/\sigma^2 \sim \chi^2_{n-2}$ (se pierden 2 g.l. por estimar β_0, β_1). Entonces $\mathbb{E}[\sum e_i^2] = (n-2)\sigma^2$ y dividir por $n-2$ da insesgadez.

Corolario 5.7 (t-test/IC para β_1)**.** *Bajo normalidad,*

$$\frac{\widehat{\beta}_1 - \beta_1}{\sqrt{\widehat{\sigma}^2/S_{xx}}} \sim t_{n-2}, \quad \beta_1 \in \left[\widehat{\beta}_1 \pm t_{1-\alpha/2,n-2}\sqrt{\frac{\widehat{\sigma}^2}{S_{xx}}}\right].$$

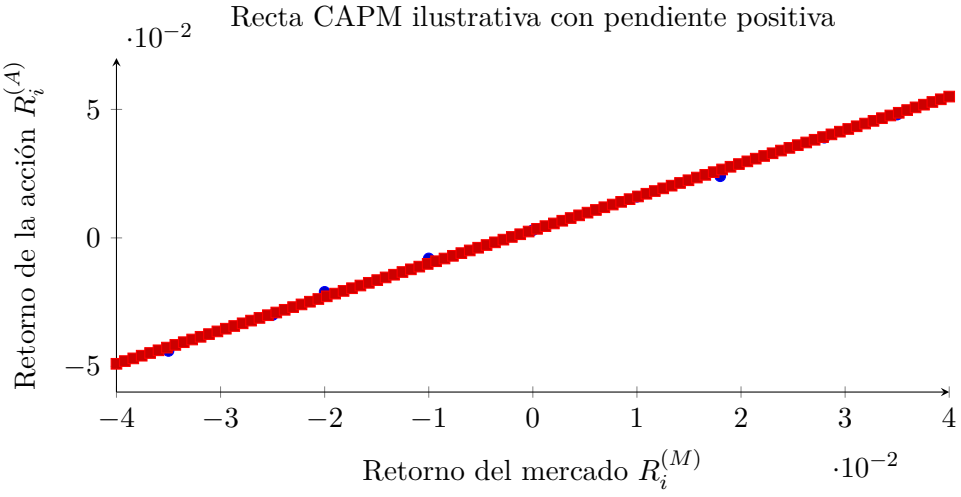
Solución. $\widehat{\beta}_1$ es normal con varianza σ^2/S_{xx}. Además, $\sum e_i^2/\sigma^2 \sim \chi^2_{n-2}$ e independencia por proyección ortogonal. Por definición, el cociente es t_{n-2}.

5.4. Ejemplos resueltos de regresión con finanzas

Ejemplo 5.8 (CAPM: beta de una acción)**.** Sea $y_i = R_i^{(A)}$ y $x_i = R_i^{(M)}$. Modelo: $R^{(A)} = \beta_0 + \beta_1 R^{(M)} + \varepsilon$. Queremos estimar β_1 y hacer IC.

Solución. Calcula $\widehat{\beta}_1 = S_{xy}/S_{xx}$ con datos. Luego $\widehat{\sigma}^2 = \sum e_i^2/(n-2)$. IC 95 %:

$$\widehat{\beta}_1 \pm t_{0{,}975,n-2}\sqrt{\widehat{\sigma}^2/S_{xx}}.$$



Ejemplo 5.9 (Duración empírica: retorno de bono vs cambio de yield)**.** Sea y_i retorno del bono y $x_i = \Delta y_i$ cambio diario del yield. Si $\widehat{\beta}_1 < 0$, el signo concuerda con duración (sube yield, baja precio).

Solución. Ajusta OLS y prueba $H_0 : \beta_1 = 0$ con estadístico t. Un $\widehat{\beta}_1$ significativamente negativo apoya la sensibilidad.

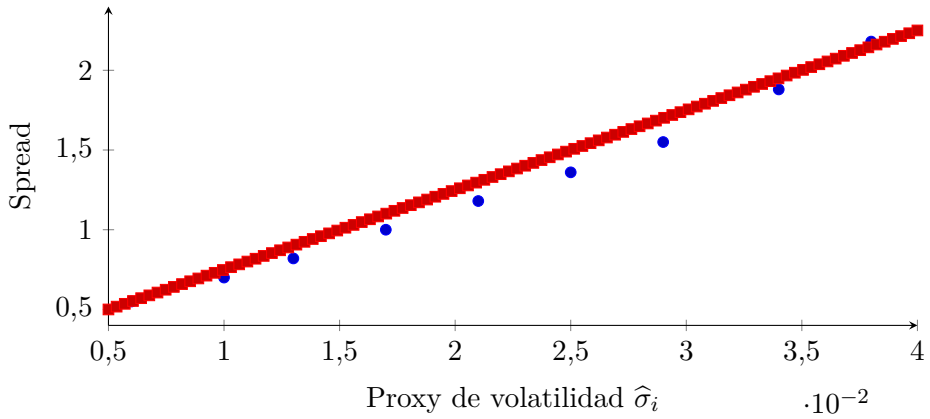
Ejemplo 5.10 (Volatilidad vs volumen)**.** Sea $y_i = |R_i|$ y $x_i = \log(\text{Vol}_i)$.

Solución. Ajusta OLS. Un $\widehat{\beta}_1 > 0$ sugiere asociación positiva entre actividad y magnitud de movimientos.

Ejemplo 5.11 (Spread vs volatilidad)**.** Sea $y_i = \text{spread}_i$ y $x_i = \widehat{\sigma}_i$ (proxy).

Solución. Ajusta OLS y prueba pendiente positiva. Interpretación microestructural: spreads más altos cuando el riesgo/información es mayor.

Relación positiva ilustrativa entre spread y volatilidad



A. Apéndice A: Prerrequisitos probabilísticos (recordatorio)

Este apéndice resume la parte de *Probabilidad* que realmente sostiene la estadística inferencial del texto. La idea es sencilla: antes de estimar, construir intervalos o definir regiones de rechazo, necesitamos saber qué es una variable aleatoria, cómo se comportan la esperanza y la varianza, por qué la independencia simplifica cálculos, y cómo las leyes límite conectan cantidades muestrales con distribuciones asintóticas. En varios de los ejercicios del apéndice siguiente se añadirá explícitamente una línea titulada *Prerrequisitos de Probabilidad usados*, para que se vea con precisión qué piezas de este apéndice intervienen.

A.1. Espacios de probabilidad y variables aleatorias

Definición A.1 (Espacio de probabilidad)**.** Un espacio de probabilidad es $(\Omega, \mathcal{F}, \mathbb{P})$: Ω espacio muestral, $\mathcal{F}$ sigma-álgebra, $\mathbb{P}$ medida de probabilidad.

Definición A.2 (Variable aleatoria, distribución)**.** Una v.a. es $X : (\Omega, \mathcal{F}) \to (\mathbb{R}, \mathcal{B})$ medible. Su CDF es $F_X(x) = \mathbb{P}(X \leq x)$.

A.2. Esperanza, varianza, covarianza (fórmulas mínimas)

Proposición A.3 (Linealidad de la esperanza)**.** *Para constantes a, b y v.a. integrables X, Y:* $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$.

Proposición A.4 (Varianza y covarianza)**.**

$$\mathrm{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2, \quad \mathrm{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Si X, Y son independientes y con segundos momentos finitos, entonces $\mathrm{Cov}(X, Y) = 0$.

Proposición A.5 (Varianza de suma)**.** *Si X_i son no correlacionadas:*

$$\mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \mathrm{Var}(X_i).$$

En particular, si i.i.d. con varianza σ^2, entonces $\mathrm{Var}(\overline{X}) = \sigma^2/n$.

Observación A.6 (Qué aporta esta subsección). Las identidades de esperanza y varianza permiten pasar de observaciones individuales a estadísticos muestrales. En particular, casi todos los cálculos de error estándar del documento parten de dos hechos:

$$\mathbb{E}[\overline{X}] = \mu, \qquad \mathrm{Var}(\overline{X}) = \frac{\sigma^2}{n},$$

y éstos dependen directamente de linealidad de la esperanza e independencia.

A.3. Desigualdades esenciales

Teorema A.7 (Markov)**.** *Si $X \geq 0$ y $\mathbb{E}[X] < \infty$, entonces $\mathbb{P}(X \geq a) \leq \mathbb{E}[X]/a$ para $a > 0$.*

Teorema A.8 (Chebyshev)**.** *Si* $\mathrm{Var}(X) < \infty$*, entonces* $\mathbb{P}(|X - \mathbb{E}[X]| \geq \varepsilon) \leq \mathrm{Var}(X)/\varepsilon^2$.

A.4. Leyes límite: LLN y CLT

Teorema A.9 (Ley débil de los grandes números (WLLN))**.** *Si X_i i.i.d. con $\mathbb{E}[X_i] = \mu$ y* $\mathrm{Var}(X_i) < \infty$*, entonces $\overline{X} \to \mu$ en probabilidad.*

Solución. Se prueba con Chebyshev como en Teorema 2.9.

Teorema A.10 (Teorema central del límite (CLT))**.** *Si X_i i.i.d. con media μ y varianza $\sigma^2 < \infty$, entonces $\sqrt{n}(\overline{X} - \mu)/\sigma \Rightarrow N(0, 1)$.*

Observación A.11. En inferencia clásica, CLT justifica IC y pruebas aproximadas fuera de normalidad cuando n es grande. En lenguaje operativo: si una media muestral está bien centrada y su dispersión se reduce como $1/n$, entonces la normal aparece como aproximación universal tras reescalar por $\sqrt{n}$.

A.5. Normal, chi-cuadrada y t: relaciones mínimas

Proposición A.12 (Normal estándar)**.** *$Z \sim N(0,1)$ si su densidad es $\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$. Cuantil z_α: $\mathbb{P}(Z \geq z_\alpha) = \alpha$.*

Proposición A.13 (Chi-cuadrada)**.** *Si $Z_1, \ldots, Z_\nu$ i.i.d. $N(0,1)$, entonces $\sum_{i=1}^{\nu} Z_i^2 \sim \chi^2_\nu$.*

Proposición A.14 (t de Student)**.** *Si $Z \sim N(0,1)$, $U \sim \chi^2_\nu$ independientes, entonces*

$$T = \frac{Z}{\sqrt{U/\nu}} \sim t_\nu.$$

Observación A.15 (Lectura inferencial)*.* Estas tres familias aparecen una y otra vez:

(1) la normal para pivotes centrados y estandarizados;

(2) la chi-cuadrada para varianzas bajo normalidad;

(3) la t cuando la varianza poblacional es desconocida y se sustituye por S.

Por eso las regiones de rechazo y los intervalos del texto tienen fronteras dadas por cuantiles z_α, $\chi^2_{\alpha,\nu}$ o $t_{\alpha,\nu}$.

A.6. Transformaciones y método delta (recordatorio corto)

Proposición A.16 (Transformación monótona en IC)**.** *Si $[L, U]$ es IC para θ y g es monótona creciente, entonces $[g(L), g(U)]$ es IC para $g(\theta)$.*

Observación A.17*.* Ej.: IC de $\sigma^2 \Rightarrow$ IC de σ usando raíz cuadrada.

B. Apéndice B: Ejercicios y soluciones completas

Guía de lectura. En las soluciones seleccionadas de este apéndice se indica explícitamente qué parte del Apéndice A está siendo usada. El objetivo es conectar cada técnica inferencial con su fundamento probabilístico mínimo.

B.1. Ejercicios con soluciones

Ejercicio B.1 (MSE y sesgo: traslación de la media)**.** Sea $\widehat{\Theta} = \overline{X} + c$ un estimador de μ, con $c \in \mathbb{R}$ constante. Encuentra el sesgo y el error cuadrático medio (MSE). Determina el valor de c que minimiza el MSE.

Solución. Prerrequisitos de Probabilidad usados. Linealidad de la esperanza y varianza de la media muestral del Subsección A.2. El paso clave es que sumar una constante cambia la esperanza pero no la varianza.

Sesgo:

$$\mathbb{E}[\overline{X} + c] - \mu = (\mu + c) - \mu = c.$$

Varianza:

$$\mathrm{Var}(\overline{X} + c) = \mathrm{Var}(\overline{X}) = \frac{\sigma^2}{n}.$$

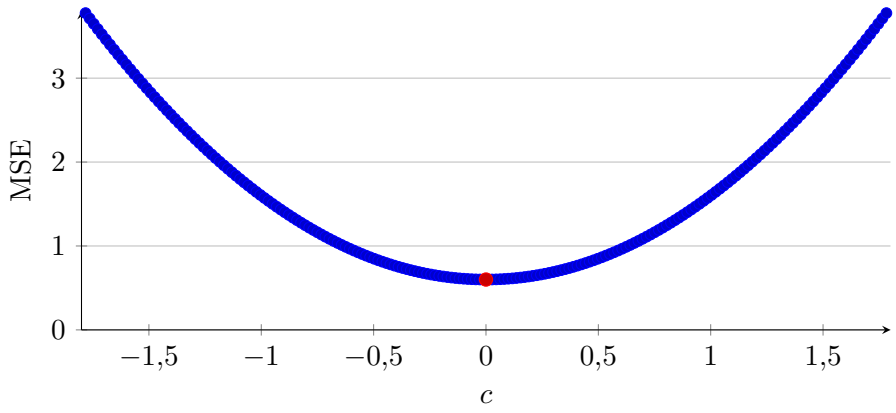
Por tanto, el error cuadrático medio es

$$\mathrm{MSE} = \mathrm{Var}(\overline{X} + c) + (\text{sesgo})^2 = \frac{\sigma^2}{n} + c^2.$$

Esta expresión se minimiza cuando $c^* = 0$. Por lo tanto, el mejor estimador dentro de esta familia (en términos de MSE) es

$$\widehat{\Theta} = \overline{X}.$$

El MSE es una parábola con mínimo en $c = 0$



Explicación de la figura. La gráfica muestra que desplazar el estimador $\overline{X}$ por una constante c introduce sesgo cuadrático c^2. Como la varianza permanece fija en σ^2/n, toda desviación de $c = 0$ aumenta el MSE.

Ejercicio B.2 (IC para σ^2 y anualización)**.** Con $n = 20$ y $S^2 = 0{,}0004$ (varianza diaria de retornos), construye un IC 95 % para σ^2 bajo normalidad. Luego da IC para σ y para σ_{anual}.

Solución. Prerrequisitos de Probabilidad usados. Relación entre normal y chi-cuadrada del Subsección A.5, junto con transformación monótona de intervalos del Subsección A.6. La parte probabilística profunda aquí es que, bajo normalidad,

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1},$$

y eso es exactamente lo que genera el pivote para el intervalo.

Grados de libertad: $\nu = n - 1 = 19$. Por Teorema 3.9 con $\alpha = 0{,}05$:

$$\sigma^2 \in \left[\frac{19S^2}{\chi^2_{0{,}975,19}},\ \frac{19S^2}{\chi^2_{0{,}025,19}} \right].$$

Usando valores típicos (aprox.): $\chi^2_{0{,}975,19} \approx 32{,}85$ y $\chi^2_{0{,}025,19} \approx 8{,}91$. Entonces

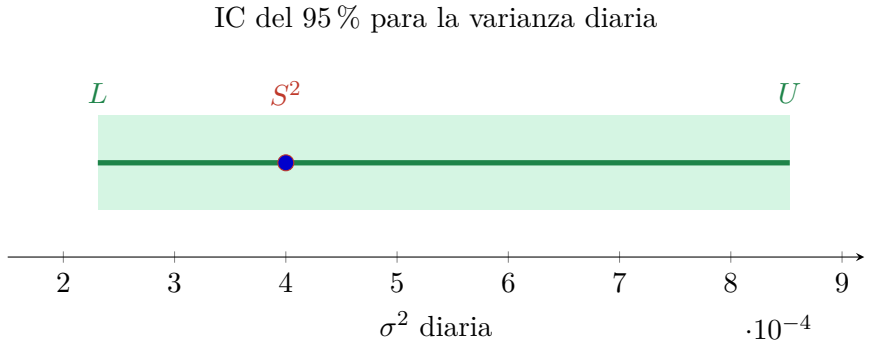
$$\mathrm{LI} = \frac{19 \cdot 0{,}0004}{32{,}85} \approx \frac{0{,}0076}{32{,}85} \approx 0{,}000231, \quad \mathrm{LS} = \frac{19 \cdot 0{,}0004}{8{,}91} \approx \frac{0{,}0076}{8{,}91} \approx 0{,}000853.$$

IC para σ: tomar raíces:

$$\sigma \in [\sqrt{0{,}000231}, \sqrt{0{,}000853}] \approx [0{,}0152,\ 0{,}0292].$$

IC para anualizada: multiplica por $\sqrt{252} \approx 15{,}874$:

$$\sigma_{\text{anual}} \in [0{,}0152 \cdot 15{,}874,\ 0{,}0292 \cdot 15{,}874] \approx [0{,}241,\ 0{,}463].$$



Explicación de la figura. El punto central representa la varianza muestral $S^2 = 0{,}0004$ y el segmento horizontal muestra el rango de valores plausibles para σ^2. Después, el mismo intervalo se transforma de manera monótona a escalas de volatilidad diaria y anualizada.

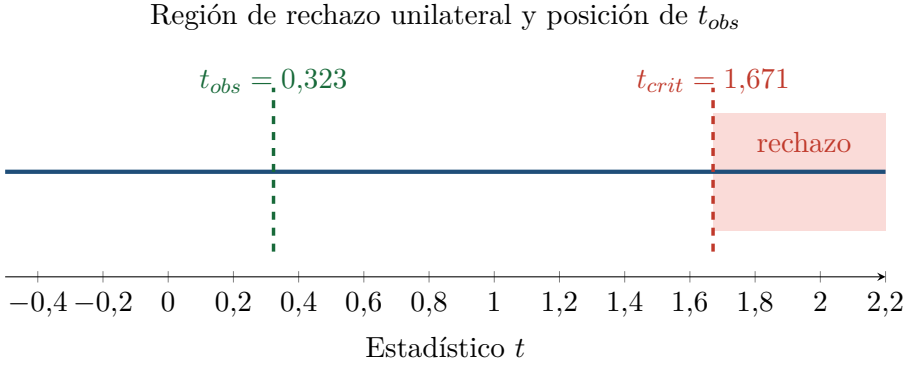
Ejercicio B.3 (t-test unilateral (retornos))**.** Retornos diarios: $n = 60$, $\overline{X} = 0{,}0005$, $S = 0{,}012$. Prueba $H_0 : \mu \leq 0$ vs $H_1 : \mu > 0$ al 5 %.

Solución. Prerrequisitos de Probabilidad usados. Distribución t de Student del Subsección A.5; además, implícitamente se usa que $\overline{X}$ resume la muestra y que su dispersión depende de $\mathrm{Var}(\overline{X}) = \sigma^2/n$ del Subsección A.2. La región de rechazo se construye con un cuantil $t_{0{,}95,59}$, es decir, con una frontera probabilística.

Es exactamente el Ejemplo de la sección de pruebas:

$$t_{\text{obs}} = \frac{0{,}0005}{0{,}012/\sqrt{60}} \approx 0{,}323.$$

Crítico $t_{0{,}95,59} \approx 1{,}671$. No se rechaza H_0.



Explicación de la figura. Como $t_{obs} = 0{,}323$ queda claramente a la izquierda del valor crítico 1,671, el estadístico observado no entra en la región de rechazo. Por eso la evidencia a favor de $\mu > 0$ es insuficiente al 5 %.

Ejercicio B.4 (CAPM: IC para beta)**.** Con $n = 120$, $S_{xx} = 0{,}018$, $\widehat{\sigma}^2 = 0{,}00009$, y $\widehat{\beta}_1 = 1{,}15$, construye un IC 95 % para β_1.

Solución. Prerrequisitos de Probabilidad usados. Uso de cuantiles de la distribución t del Subsección A.5 y, detrás del error estándar, la lógica de esperanza/varianza de combinaciones lineales del Subsección A.2. En regresión lineal, el intervalo sale de estandarizar el estimador y compararlo con una ley t.

Grados de libertad: $n - 2 = 118$. Error estándar:

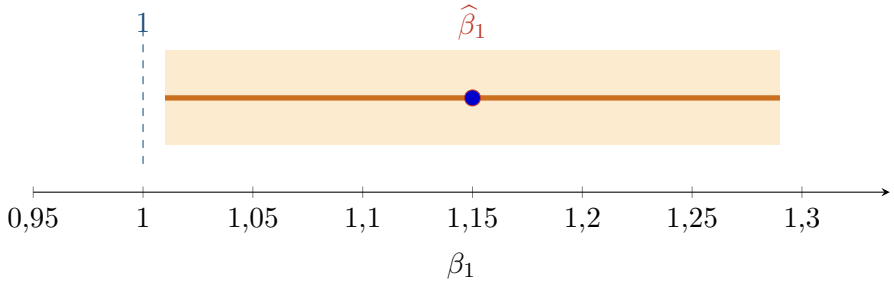
$$\widehat{\mathrm{se}}(\widehat{\beta}_1) = \sqrt{\frac{\widehat{\sigma}^2}{S_{xx}}} = \sqrt{\frac{0{,}00009}{0{,}018}} = \sqrt{0{,}005} = 0{,}0707107.$$

Cuantil $t_{0{,}975,118} \approx 1{,}98$ (muy cercano a 1.96). Semiancho $\approx 1{,}98 \cdot 0{,}07071 \approx 0{,}1400$. Por tanto:

$$\beta_1 \in [1{,}15 - 0{,}14,\ 1{,}15 + 0{,}14] = [1{,}01,\ 1{,}29] \text{ (aprox.)}.$$

Interpretación: beta es consistentemente mayor que 1 (casi justo), alta exposición al mercado.

IC del 95 % para la beta CAPM



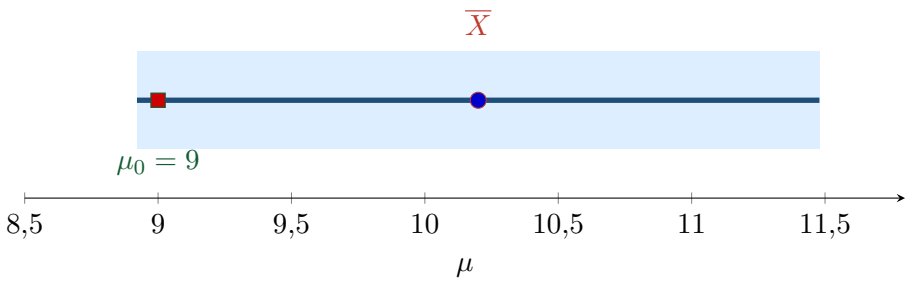
Explicación de la figura. El segmento muestra que casi todo el rango plausible para β_1 está por encima de 1. Eso sugiere una acción con sensibilidad al mercado ligeramente superior a la unidad.

Ejercicio B.5 (Ejercicio extra: IC de media y decisión por dualidad)**.** Con $n = 16$, $\overline{X} = 10{,}2$, $S = 2{,}4$ y suponer normalidad. (i) Construye IC 95 % para μ. (ii) Decide si rechazas $H_0 : \mu = 9$ al 5 % (bilateral) usando dualidad.

Solución. Prerrequisitos de Probabilidad usados. Distribución t del Subsección A.5 y la interpretación de cuantiles probabilísticos. La dualidad con la prueba bilateral se apoya en que el mismo pivote aleatorio produce simultáneamente el intervalo y la región de rechazo.

(i) $\nu = 15$, $t_{0{,}975,15} \approx 2{,}131$. Semiancho: $2{,}131 \cdot 2{,}4/\sqrt{16} = 2{,}131 \cdot 0{,}6 = 1{,}2786$. IC: $10{,}2 \pm 1{,}279 \Rightarrow [8{,}921,\ 11{,}479]$. (ii) Como $9 \in [8{,}921, 11{,}479]$, *no* se rechaza H_0 al 5 %.

Dualidad entre IC y prueba bilateral



Explicación de la figura. El valor nulo $\mu_0 = 9$ cae dentro del intervalo de confianza del 95 %. Esa inclusión visualiza inmediatamente la dualidad: si el valor hipotético pertenece al IC, la prueba bilateral no rechaza H_0 al mismo nivel.