Estadística Inferencial clásica

Métodos clásicos

César Galindo

Índice

1. Preliminares: modelo, muestra, estadísticos **2**
1.1. Modelo paramétrico y muestra i.i.d. . . . 2
1.2. Ejemplos resueltos de modelado . . . 2

2. Estimación puntual: sesgo, varianza, MSE; MLE **4**
2.1. Criterios de calidad . . . 4
2.2. Media y varianza muestral (pruebas completas) . . . 5
2.3. Máxima verosimilitud (MLE): teoría y pruebas . . . 5
2.4. Ejemplos resueltos de MLE y estimación puntual . . . 6

3. Intervalos de confianza: pivotes, CLT, t y χ^2 **7**
3.1. Pivotes e intervalos . . . 7
3.2. IC aproximado para μ (CLT) y tamaño de muestra . . . 8
3.3. Normal exacto: χ^2 para σ^2 y t para μ . . . 8
3.4. Ejemplos resueltos de IC, incluyendo finanzas . . . 9

4. Pruebas de hipótesis: nivel, potencia, p-value; razón de verosimilitud **12**
4.1. Definiciones básicas . . . 12
4.2. Neyman–Pearson (hipótesis simples) con prueba completa . . . 12
4.3. Pruebas para media: z y t; dualidad IC–prueba . . . 12
4.4. Ejemplos resueltos de pruebas, incluyendo finanzas . . . 13

5. Regresión lineal: mínimos cuadrados, propiedades, inferencia **15**
5.1. Modelo y estimadores OLS . . . 15
5.2. Insesgadez, varianzas y Gauss–Markov (pruebas completas) . . . 16
5.3. Inferencia exacta bajo normalidad . . . 17
5.4. Ejemplos resueltos de regresión con finanzas . . . 17

A. Apéndice A: Prerrequisitos probabilísticos (recordatorio) **19**
A.1. Espacios de probabilidad y variables aleatorias . . . 19
A.2. Esperanza, varianza, covarianza (fórmulas mínimas) . . . 19
A.3. Desigualdades esenciales . . . 19
A.4. Leyes límite: LLN y CLT . . . 20
A.5. Normal, chi-cuadrada y t: relaciones mínimas . . . 20
A.6. Transformaciones y método delta (recordatorio corto) . . . 20

B. Apéndice B: Ejercicios y soluciones completas **20**
B.1. Ejercicios con soluciones 21

1. Preliminares: modelo, muestra, estadísticos

1.1. Modelo paramétrico y muestra i.i.d.

Definición 1.1 (Modelo estadístico paramétrico)**.** Un *modelo estadístico* es una familia $\{P_\theta : \theta \in \Theta\}$ de distribuciones para la muestra $X = (X_1, \dots, X_n)$. En el enfoque frecuentista, θ es una constante desconocida; la aleatoriedad está en X.

Definición 1.2 (Muestra aleatoria i.i.d.)**.** Decimos que $X_1, \dots, X_n$ es una *muestra aleatoria i.i.d.* si son independientes y con la misma distribución.

Definición 1.3 (Estadístico)**.** Un *estadístico* es una función medible $T = h(X_1, \dots, X_n)$.

Lema 1.4 (Media y varianza de la media muestral)**.** *Si $X_1, \dots, X_n$ son i.i.d. con $\mathbb{E}[X_i] = \mu$ y $\mathrm{Var}(X_i) = \sigma^2 < \infty$, entonces*

$$\mathbb{E}[\overline{X}] = \mu, \qquad \mathrm{Var}(\overline{X}) = \frac{\sigma^2}{n}.$$

Solución. Por linealidad, $\mathbb{E}[\overline{X}] = \frac{1}{n}\sum_{i=1}^n \mathbb{E}[X_i] = \mu$. Por independencia, $\mathrm{Var}(\sum X_i) = \sum \mathrm{Var}(X_i) = n\sigma^2$; así $\mathrm{Var}(\overline{X}) = \mathrm{Var}(\sum X_i)/n^2 = \sigma^2/n$.

Observación 1.5 (Plantilla de modelado). **(1)** Define una observación X_i (retorno diario, tiempo entre eventos, etc.).

(2) Decide si i.i.d. es razonable (o como aproximación en una ventana temporal).

(3) Elige parámetro θ (media, volatilidad, tasa de default, β CAPM, etc.).

(4) Elige estadístico(s) (media, varianza, MLE, OLS, etc.).

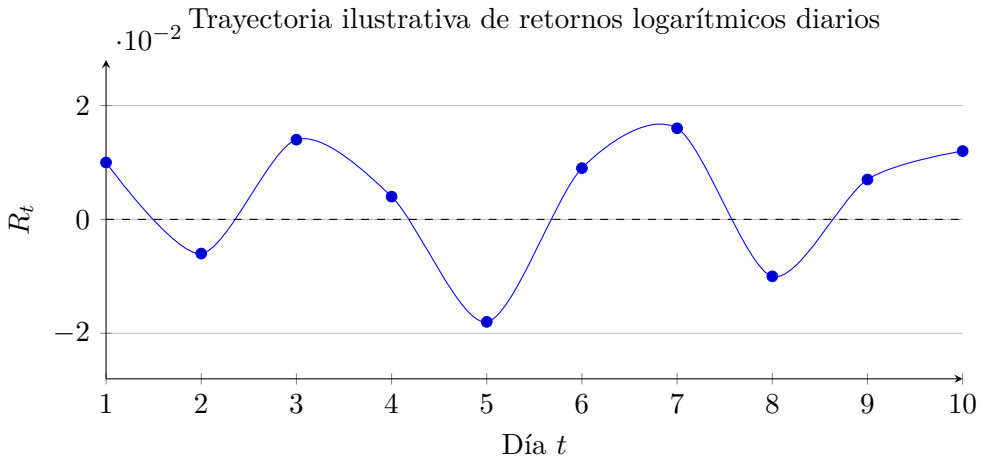
1.2. Ejemplos resueltos de modelado

Ejemplo 1.6 (Retornos logarítmicos (finanzas))**.** Sea P_t el precio de cierre. Define retorno logarítmico diario

$$R_t = \log\left(\frac{P_t}{P_{t-1}}\right).$$

En una ventana corta (mercado "estable"), se usa el modelo $R_1, \dots, R_n$ i.i.d. con $\mathbb{E}[R_i] = \mu$ y $\mathrm{Var}(R_i) = \sigma^2$.

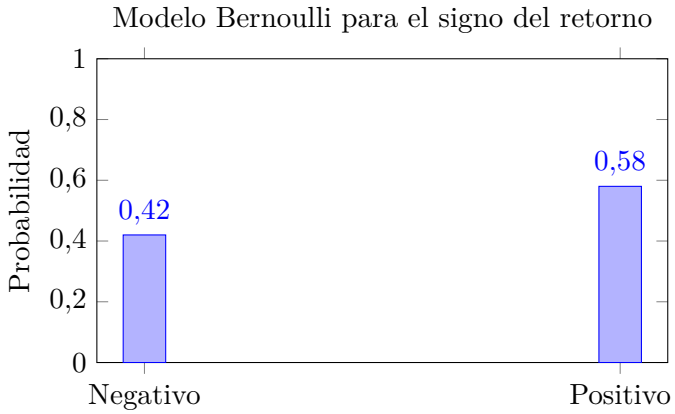
Solución. La hipótesis i.i.d. no es una verdad universal: es una aproximación local. En inferencia clásica, fijamos un modelo *operativo* y cuantificamos incertidumbre sobre μ y σ^2.



Explicación de la figura. La trayectoria no pretende probar normalidad ni independencia; sólo muestra la clase de serie sobre la que luego se estima una media, una varianza y se construyen intervalos o pruebas. En práctica, el signo cambiante de los retornos sugiere que la señal promedio puede ser pequeña respecto al ruido.

Ejemplo 1.7 (Día positivo (finanzas))**.** Define $X_i = \mathbb{1}_{\{R_i>0\}}$. Entonces $X_i \in \{0,1\}$ y se modela como Bernoulli con parámetro $p = \mathbb{P}(R > 0)$; $\overline{X}$ estima p.

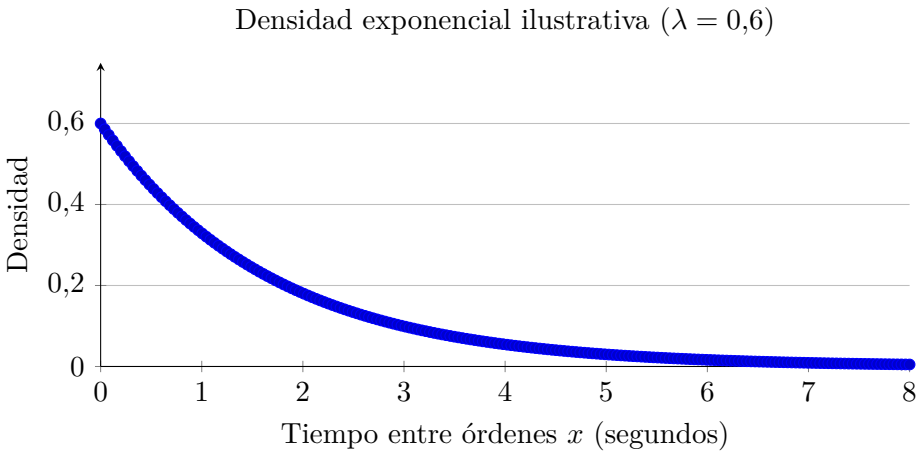
Solución. Bajo Bernoulli(p), $\mathbb{E}[X_i] = p$ y $\mathrm{Var}(X_i) = p(1-p)$. La estimación natural de p es $\widehat{p} = \overline{X}$ (también es MLE; ver Theorem 2.13).



Explicación de la figura. La barra de "Positivo" mayor que la de "Negativo" representa un escenario en el que la probabilidad de un día ganador supera 50 %. Este tipo de visualización ayuda a traducir un parámetro abstracto p en una lectura operativa inmediata.

Ejemplo 1.8 (Tiempos entre órdenes (microestructura))**.** Sea X_i el tiempo (en segundos) entre dos órdenes consecutivas en un activo. Un modelo base es $X_i \sim \mathrm{Exp}(\lambda)$ i.i.d.

Solución. Aquí λ es la *intensidad* (órdenes por segundo). El estimador MLE es $\widehat{\lambda} = 1/\overline{X}$ (ver Theorem 2.14).



Explicación de la figura. La densidad exponencial decrece rápidamente: tiempos muy cortos entre órdenes son más frecuentes que tiempos largos. En business analytics esto suele interpretarse como actividad concentrada en lapsos breves con eventos largos relativamente raros.

Ejemplo 1.9 (Tasa de defecto (industria / riesgo))**.** Sea $X_i = \mathbb{1}_{\{\text{defecto}\}}$. Se modela $X_i \sim \text{Bern}(p)$ i.i.d. El parámetro p es la tasa de defecto.

Solución. La inferencia clásica produce (i) estimación puntual $\widehat{p}$ y (ii) IC o pruebas sobre p.

2. Estimación puntual: sesgo, varianza, MSE; MLE

2.1. Criterios de calidad

Definición 2.1 (Estimador y estimación)**.** Un *estimador* de θ es una v.a. $\widehat{\Theta} = h(X_1, \ldots, X_n)$. La *estimación* es el valor observado $\widehat{\theta} = h(x_1, \ldots, x_n)$.

Definición 2.2 (Sesgo y MSE)**.**

$$\text{Bias}_\theta(\widehat{\Theta}) = \mathbb{E}_\theta[\widehat{\Theta}] - \theta, \qquad \text{MSE}_\theta(\widehat{\Theta}) = \mathbb{E}_\theta\left[(\widehat{\Theta} - \theta)^2\right].$$

Teorema 2.3 (Descomposición sesgo–varianza)**.** *Para todo estimador* $\widehat{\Theta}$ *con segundo momento finito,*

$$\text{MSE}_\theta(\widehat{\Theta}) = \text{Var}_\theta(\widehat{\Theta}) + \text{Bias}_\theta(\widehat{\Theta})^2.$$

Solución. Sea $b = \mathbb{E}[\widehat{\Theta}] - \theta$. Entonces $\widehat{\Theta} - \theta = (\widehat{\Theta} - \mathbb{E}[\widehat{\Theta}]) + b$. Al cuadrar y tomar esperanza:

$$\mathbb{E}[(\widehat{\Theta} - \theta)^2] = \mathbb{E}[(\widehat{\Theta} - \mathbb{E}[\widehat{\Theta}])^2] + 2b\,\mathbb{E}[\widehat{\Theta} - \mathbb{E}[\widehat{\Theta}]] + b^2 = \text{Var}(\widehat{\Theta}) + b^2.$$

Corolario 2.4 (Insesgadez reduce MSE a varianza)**.** *Si* $\widehat{\Theta}$ *es insesgado, entonces* $\text{MSE}_\theta(\widehat{\Theta}) = \text{Var}_\theta(\widehat{\Theta})$.

Solución. Si Bias $= 0$, aplica Theorem 2.3.

2.2. Media y varianza muestral (pruebas completas)

Definición 2.5 (Media y varianza muestral)**.**

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2.$$

Proposición 2.6 (Insesgadez de $\overline{X}$)**.** *Si* $\mathbb{E}[X_i] = \mu$*, entonces* $\mathbb{E}[\overline{X}] = \mu$*.*

Solución. Es la primera igualdad del Theorem 1.4.

Lema 2.7 (Identidad de descomposición de cuadrados)**.** *Para cualquier números* $x_1, \ldots, x_n$ *y cualquier* $a \in \mathbb{R}$*,*

$$\sum_{i=1}^{n}(x_i - \overline{x})^2 = \sum_{i=1}^{n}(x_i - a)^2 - n(\overline{x} - a)^2, \quad \overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Solución. Escribe $x_i - \overline{x} = (x_i - a) - (\overline{x} - a)$ y expande:

$$\sum (x_i - \overline{x})^2 = \sum (x_i - a)^2 - 2(\overline{x} - a)\sum (x_i - a) + \sum (\overline{x} - a)^2.$$

Pero $\sum(x_i - a) = n(\overline{x} - a)$ y $\sum(\overline{x} - a)^2 = n(\overline{x} - a)^2$. Sustituyendo queda la identidad.

Teorema 2.8 (Insesgadez de S^2)**.** *Si* $X_1, \ldots, X_n$ *son i.i.d. con varianza* σ^2*, entonces* $\mathbb{E}[S^2] = \sigma^2$*.*

Solución. Sea $\mu = \mathbb{E}[X_i]$. Aplica Theorem 2.7 con $a = \mu$ y $x_i = X_i$:

$$\sum (X_i - \overline{X})^2 = \sum (X_i - \mu)^2 - n(\overline{X} - \mu)^2.$$

Toma esperanza:

$$\mathbb{E}\Big[\sum (X_i - \overline{X})^2\Big] = \sum \mathbb{E}[(X_i - \mu)^2] - n\,\mathbb{E}[(\overline{X} - \mu)^2] = n\sigma^2 - n\,\mathrm{Var}(\overline{X}).$$

Por Theorem 1.4, $\mathrm{Var}(\overline{X}) = \sigma^2/n$; así la esperanza vale $(n-1)\sigma^2$. Divide por $n-1$ para obtener $\mathbb{E}[S^2] = \sigma^2$.

Corolario 2.9 (Consistencia de $\overline{X}$)**.** *Si* $\mathrm{Var}(X_i) = \sigma^2 < \infty$*, entonces* $\overline{X} \to \mu$ *en probabilidad cuando* $n \to \infty$*.*

Solución. Por Chebyshev: $\mathbb{P}(|\overline{X} - \mu| \geq \varepsilon) \leq \mathrm{Var}(\overline{X})/\varepsilon^2 = (\sigma^2/n)/\varepsilon^2 \to 0$.

2.3. Máxima verosimilitud (MLE): teoría y pruebas

Definición 2.10 (Verosimilitud y log-verosimilitud)**.** Si la densidad/pmf es $f(x;\theta)$, para datos $(x_1, \ldots, x_n)$ se define

$$L(\theta) = \prod_{i=1}^{n} f(x_i;\theta), \qquad \ell(\theta) = \log L(\theta) = \sum_{i=1}^{n} \log f(x_i;\theta).$$

Un *MLE* es un $\widehat{\theta}$ que maximiza $L(\theta)$ (equiv. $\ell(\theta)$).

Teorema 2.11 (Invarianza del MLE)**.** *Si $\widehat{\theta}$ es MLE de θ y g es una función tal que $g(\widehat{\theta})$ está bien definida, entonces $g(\widehat{\theta})$ es un MLE de $g(\theta)$ (verosimilitud perfilada).*

Solución. Para $u = g(\theta)$ define la verosimilitud perfilada $\widetilde{L}(u) = \sup_{\theta:\, g(\theta)=u} L(\theta)$. Como $L(\widehat{\theta}) \geq L(\theta)$ para toda θ, se tiene $\widetilde{L}(u) \leq L(\widehat{\theta})$ para todo u, con igualdad en $u = g(\widehat{\theta})$. Por tanto $g(\widehat{\theta})$ maximiza $\widetilde{L}$.

Observación 2.12 (Plantilla MLE). **(1)** Escribe $L(\theta)$ y luego $\ell(\theta)$.

(2) Resuelve $\ell'(\theta) = 0$ (o gradiente $= 0$).

(3) Verifica máximo (segunda derivada / concavidad / frontera).

(4) Si piden $g(\theta)$, usa invarianza.

2.4. Ejemplos resueltos de MLE y estimación puntual

Ejemplo 2.13 (Bernoulli: MLE de p)**.** Si $X_i \sim \text{Bern}(p)$, entonces el MLE es $\widehat{p} = \overline{X}$.

Solución. Con $S = \sum x_i$:

$$L(p) = \prod p^{x_i}(1-p)^{1-x_i} = p^S(1-p)^{n-S}, \quad \ell(p) = S\log p + (n-S)\log(1-p).$$

Deriva:

$$\ell'(p) = \frac{S}{p} - \frac{n-S}{1-p} = 0 \iff S(1-p) = p(n-S) \iff \widehat{p} = \frac{S}{n} = \overline{X}.$$

Además $\ell''(p) = -S/p^2 - (n-S)/(1-p)^2 < 0$ para $0 < p < 1$, luego es máximo interior.

Ejemplo 2.14 (Exponencial: MLE de λ)**.** Si $X_i \sim \text{Exp}(\lambda)$ (densidad $\lambda e^{-\lambda x}$, $x \geq 0$), entonces $\widehat{\lambda} = 1/\overline{X}$.

Solución.

$$\ell(\lambda) = \sum(\log\lambda - \lambda x_i) = n\log\lambda - \lambda\sum x_i, \quad \ell'(\lambda) = \frac{n}{\lambda} - \sum x_i.$$

Igualando a cero: $\widehat{\lambda} = n/\sum x_i = 1/\overline{X}$. Como $\ell''(\lambda) = -n/\lambda^2 < 0$, es máximo.

Ejemplo 2.15 (Normal: MLE de μ y σ^2)**.** Si $X_i \sim N(\mu, \sigma^2)$ i.i.d., entonces

$$\widehat{\mu}_{\text{ML}} = \overline{X}, \qquad \widehat{\sigma^2}_{\text{ML}} = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2 = \frac{n-1}{n}S^2.$$

Solución. La log-verosimilitud (omitiendo constantes) es

$$\ell(\mu, \sigma^2) = -\frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2}\sum(x_i - \mu)^2.$$

Para μ:

$$\frac{\partial\ell}{\partial\mu} = \frac{1}{\sigma^2}\sum(x_i - \mu) = 0 \iff \widehat{\mu} = \overline{X}.$$

Sustituye $\mu = \overline{X}$:

$$\ell(\sigma^2) = -\frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2}\sum (x_i - \overline{X})^2.$$

Deriva:

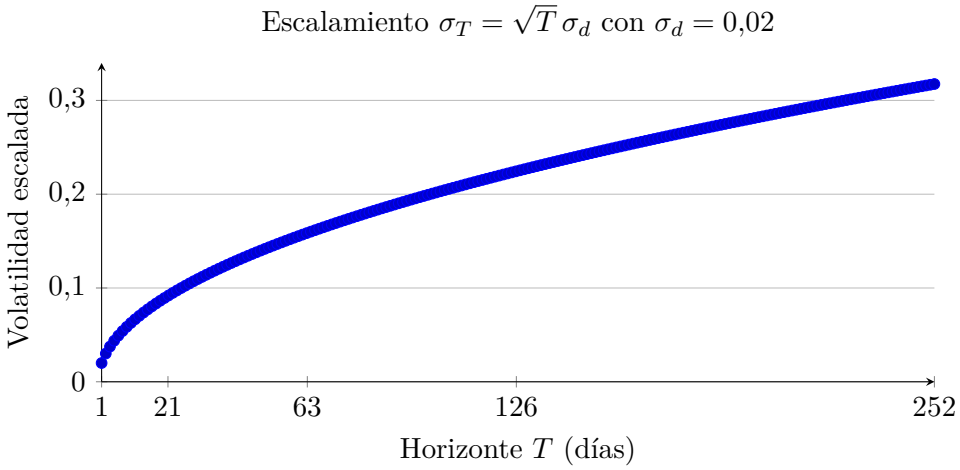
$$\frac{d\ell}{d\sigma^2} = -\frac{n}{2}\frac{1}{\sigma^2} + \frac{1}{2}\frac{\sum (x_i - \overline{X})^2}{(\sigma^2)^2} = 0 \iff \widehat{\sigma^2} = \frac{1}{n}\sum (x_i - \overline{X})^2.$$

La segunda derivada es negativa en el máximo.

Ejemplo 2.16 (Volatilidad anualizada (finanzas): estimación puntual)**.** Con retornos diarios R_i en una ventana estable y modelo $R_i \sim N(\mu, \sigma^2)$:

$$\widehat{\sigma}_{\text{diaria}} = \sqrt{S^2}, \qquad \widehat{\sigma}_{\text{anual}} = \sqrt{252}\,\widehat{\sigma}_{\text{diaria}}.$$

Solución. La insesgadez de S^2 para σ^2 es Theorem 2.8. La anualización usa la regla $\text{Var}(\sum_{t=1}^{T} R_t) = T\sigma^2$ bajo independencia, por lo que la desviación estándar escala como $\sqrt{T}$.



3. Intervalos de confianza: pivotes, CLT, t y χ^2

3.1. Pivotes e intervalos

Definición 3.1 (Intervalo de confianza)**.** Un intervalo aleatorio $[L(X), U(X)]$ es un IC de nivel $1-\alpha$ si $\mathbb{P}_\theta(L(X) \le \theta \le U(X)) = 1-\alpha$ (o $\ge 1-\alpha$).

Definición 3.2 (Pivote)**.** Una v.a. $Q(X, \theta)$ es un *pivote* si su distribución no depende de θ.

Proposición 3.3 (Método del pivote)**.** *Si $Q(X,\theta)$ es pivote y existen $a < b$ con $\mathbb{P}(a \le Q \le b) = 1-\alpha$ y $a \le Q(X,\theta) \le b \iff L(X) \le \theta \le U(X)$, entonces $[L(X), U(X)]$ es un IC $1-\alpha$.*

Solución. Por equivalencia de eventos, sus probabilidades coinciden.

3.2. IC aproximado para μ (CLT) y tamaño de muestra

Teorema 3.4 (CLT (recordatorio operativo)). *Si X_i i.i.d. con $\mathbb{E}[X_i] = \mu$ y $\mathrm{Var}(X_i) = \sigma^2 < \infty$, entonces*

$$\frac{\sqrt{n}(\overline{X} - \mu)}{\sigma} \Rightarrow N(0,1).$$

Observación 3.5. En un curso básico se toma este teorema como prerrequisito (ver Apéndice A).

Teorema 3.6 (IC aproximado para μ con σ conocida). *Para n grande, aproximadamente*

$$\mu \in \left[\overline{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}},\ \overline{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right].$$

Solución. Por Theorem 3.4, $Z_n = (\overline{X} - \mu)/(\sigma/\sqrt{n}) \approx N(0,1)$. Entonces $\mathbb{P}(|Z_n| \le z_{\alpha/2}) \approx 1 - \alpha$. Despeja μ.

Corolario 3.7 (Tamaño muestral para margen E). *Si quieres semiancho $\le E$, basta tomar*

$$n \ge \left(\frac{z_{\alpha/2}\sigma}{E}\right)^2.$$

Solución. El semiancho del IC es $z_{\alpha/2}\sigma/\sqrt{n}$; impón $\le E$.

3.3. Normal exacto: χ^2 para σ^2 y t para μ

Teorema 3.8 (Cochran: $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$). *Si $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ i.i.d., entonces*

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}.$$

Solución. Escribe $X_i = \mu + \sigma Z_i$ con $Z_i \sim N(0,1)$ i.i.d. Entonces

$$\sum (X_i - \overline{X})^2 = \sigma^2 \sum (Z_i - \overline{Z})^2.$$

El vector $Z \in \mathbb{R}^n$ es normal estándar e invariante por rotaciones. La descomposición ortogonal $\mathbb{R}^n = \mathrm{span}\{\mathbf{1}\} \oplus \mathbf{1}^\perp$ separa una coordenada (promedio) y $n-1$ coordenadas ortogonales independientes $N(0,1)$. La suma $\sum (Z_i - \overline{Z})^2$ es la suma de cuadrados de esas $n-1$ normales, luego tiene distribución χ^2_{n-1}.

Corolario 3.9 (IC exacto para σ^2). *Sea $\chi^2_{\gamma,\nu}$ el cuantil tal que $\mathbb{P}(\chi^2_\nu \le \chi^2_{\gamma,\nu}) = \gamma$. Entonces un IC exacto $1-\alpha$ para σ^2 es*

$$\sigma^2 \in \left[\frac{(n-1)S^2}{\chi^2_{1-\alpha/2,n-1}},\ \frac{(n-1)S^2}{\chi^2_{\alpha/2,n-1}}\right].$$

Solución. Usa el pivote $Q = (n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$ y encierra Q entre cuantiles de colas iguales: $\mathbb{P}(\chi^2_{\alpha/2,n-1} \le Q \le \chi^2_{1-\alpha/2,n-1}) = 1 - \alpha$. Despeja σ^2.

Teorema 3.10 (Pivote t para μ con σ desconocida)**.** *Si $X_1, \ldots, X_n \sim N(\mu, \sigma^2)$ i.i.d., entonces*

$$T = \frac{\overline{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Solución. Bajo normalidad, $Z = (\overline{X} - \mu)/(\sigma/\sqrt{n}) \sim N(0,1)$. Por Theorem 3.8, $U = (n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$. Además $\overline{X}$ es independiente de S^2 en el caso normal (misma descomposición ortogonal). Entonces

$$T = \frac{Z}{\sqrt{U/(n-1)}} \sim t_{n-1}$$

por definición de la distribución t.

Corolario 3.11 (IC exacto para μ)**.** *Un IC exacto $1-\alpha$ para μ es*

$$\mu \in \left[\overline{X} - t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}},\ \overline{X} + t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}}\right].$$

Solución. Por Theorem 3.10, $\mathbb{P}(|T| \le t_{1-\alpha/2,n-1}) = 1-\alpha$. Despeja μ.

3.4. Ejemplos resueltos de IC, incluyendo finanzas

Ejemplo 3.12 (IC para media de retornos (finanzas))**.** Con retornos $R_1, \ldots, R_n$ y suponer normalidad, un IC 95 % para μ es

$$\overline{X} \pm t_{0{,}975,n-1}\frac{S}{\sqrt{n}}.$$

Solución. Si $R_1, \ldots, R_n \sim N(\mu, \sigma^2)$ i.i.d. y σ es desconocida, el pivote exacto es

$$T = \frac{\overline{R} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

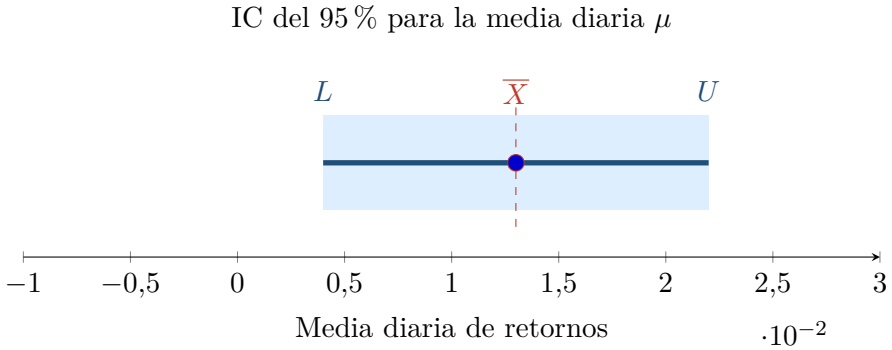
Para 95 % de confianza tomamos $\alpha = 0{,}05$ y por tanto

$$\mathbb{P}\left(-t_{0{,}975,n-1} \le \frac{\overline{R} - \mu}{S/\sqrt{n}} \le t_{0{,}975,n-1}\right) = 0{,}95.$$

Despejando μ se obtiene

$$\mu \in \left[\overline{R} - t_{0{,}975,n-1}\frac{S}{\sqrt{n}},\ \overline{R} + t_{0{,}975,n-1}\frac{S}{\sqrt{n}}\right].$$

Interpretación business: este intervalo entrega el rango de valores plausibles para el rendimiento medio diario de la estrategia o del activo. Si todo el intervalo estuviera por arriba de 0, tendríamos evidencia de rentabilidad media positiva; si contiene al 0, la evidencia es débil o ambigua.



Explicación de la figura. La franja azul representa el conjunto de valores plausibles para la media poblacional μ al 95 %. El punto rojo es la media muestral $\overline{X}$, que funciona como centro del intervalo. Cuanto más corto es el segmento azul, mayor es la precisión de la estimación.

Ejemplo 3.13 (IC para volatilidad (finanzas))**.** Bajo normalidad, un IC 95 % para σ^2 es el de Theorem 3.9 con $\alpha = 0{,}05$. Para σ toma raíz cuadrada; para anualizar multiplica por $\sqrt{252}$.

Solución. Bajo normalidad, el pivote

$$Q = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$$

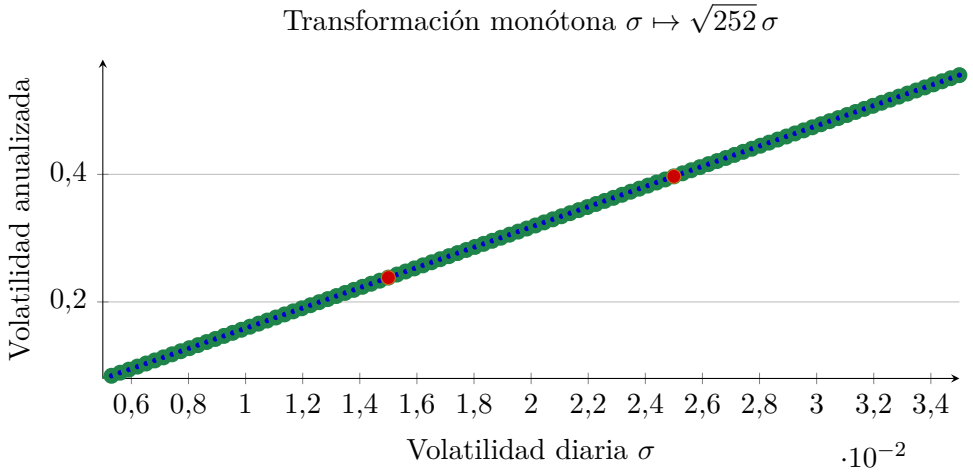
permite construir primero un IC exacto para σ^2:

$$\sigma^2 \in \left[\frac{(n-1)S^2}{\chi^2_{0{,}975,n-1}},\ \frac{(n-1)S^2}{\chi^2_{0{,}025,n-1}} \right].$$

Luego aplicamos dos transformaciones económicas muy naturales:

$$\sigma = \sqrt{\sigma^2}, \qquad \sigma_{\text{anual}} = \sqrt{252}\,\sigma.$$

Como tanto la raíz cuadrada como la multiplicación por $\sqrt{252}$ son transformaciones monótonas crecientes, basta transformar extremo inferior y extremo superior. En términos financieros, este ejemplo muestra cómo pasar de incertidumbre en la varianza diaria a incertidumbre en una medida mucho más interpretable para gestión de riesgo: la volatilidad anualizada.



Explicación de la figura. La recta verde muestra que anualizar volatilidad es una transformación lineal creciente. Si un valor diario es plausible, su versión anualizada también lo es al transformar ambos extremos del intervalo. Los puntos naranjas ilustran cómo cambian dos niveles diarios típicos al pasar a escala anual.

Ejemplo 3.14 (IC aproximado para proporción de días positivos)**.** Con $X_i = \mathbb{1}_{\{R_i>0\}}$ y n grande, un IC aproximado $1-\alpha$ para p es

$$\overline{X} \pm z_{\alpha/2}\sqrt{\frac{\overline{X}(1-\overline{X})}{n}}.$$

Solución. Como $X_i = \mathbf{1}_{\{R_i>0\}}$, tenemos $X_i \sim \text{Bernoulli}(p)$ y

$$\mathbb{E}[X_i] = p, \qquad \text{Var}(X_i) = p(1-p).$$

Entonces

$$\overline{X} = \widehat{p}, \qquad \text{Var}(\widehat{p}) \approx \frac{p(1-p)}{n}.$$

Para n grande, el CLT da

$$\frac{\widehat{p}-p}{\sqrt{p(1-p)/n}} \approx N(0,1).$$

Como p es desconocido, sustituimos p por $\widehat{p} = \overline{X}$, obteniendo el IC Wald

$$\widehat{p} \pm z_{\alpha/2}\sqrt{\frac{\widehat{p}(1-\widehat{p})}{n}}.$$

Interpretación de negocio: el intervalo cuantifica la incertidumbre en la fracción de días "ganadores" de una estrategia. No basta decir que el porcentaje observado fue alto; hay que medir cuán estable podría ser ese porcentaje en la población.

Ejemplo 3.15 (Tamaño muestral para margen de error del spread medio)**.** Si el spread diario S_i tiene desviación típica aproximada $\sigma \approx 0{,}8$ centavos y deseas margen $E = 0{,}2$ centavos con 95 % de confianza usando aproximación normal, toma

$$n \geq \left(\frac{1{,}96 \cdot 0{,}8}{0{,}2}\right)^2 = (7{,}84)^2 \approx 61{,}47,$$

así que $n = 62$ días.

Solución. La fórmula general para controlar un margen de error E en un IC normal para la media es

$$n \geq \left(\frac{z_{\alpha/2}\sigma}{E}\right)^2.$$

Aquí el problema es operacional: ¿cuántos días de datos necesito para estimar el spread promedio con precisión útil para trading o microestructura? Sustituyendo $z_{0{,}025} = 1{,}96$, $\sigma = 0{,}8$ y $E = 0{,}2$ obtenemos

$$n \geq \left(\frac{1{,}96 \cdot 0{,}8}{0{,}2}\right)^2 \approx 61{,}47.$$

Como el tamaño de muestra debe ser entero y además queremos garantizar el margen deseado, redondeamos hacia arriba: $n = 62$.

4. Pruebas de hipótesis: nivel, potencia, p-value; razón de verosimilitud

4.1. Definiciones básicas

Definición 4.1 (Prueba, región crítica, nivel)**.** Una prueba es una función $\varphi(X) \in \{0,1\}$: *rechaza* H_0 si $\varphi = 1$. Su *nivel* es $\sup_{\theta\in\Theta_0} \mathbb{E}_\theta[\varphi] \le \alpha$ (control de error tipo I).

Definición 4.2 (Errores tipo I/II; potencia)**.** Error tipo I: rechazar H_0 siendo cierta (probabilidad $\le \alpha$). Error tipo II: no rechazar H_0 siendo falsa (probabilidad $\beta(\theta)$). Potencia: $1-\beta(\theta)$.

Definición 4.3 (p-value (forma estándar))**.** Dado estadístico W y valor observado w_{obs}, el p-value es $\mathbb{P}_{H_0}(\text{“tan extremo o más” que } w_{\text{obs}})$ en la dirección de H_1.

4.2. Neyman–Pearson (hipótesis simples) con prueba completa

Teorema 4.4 (Neyman–Pearson (simples))**.** *Para $H_0 : f_0$ vs $H_1 : f_1$, la prueba de razón de verosimilitudes*

$$\varphi^*(x) = \mathbf{1}_{\{\Lambda(x)\le c\}}, \qquad \Lambda(x) = \frac{f_0(x)}{f_1(x)},$$

con c elegido de modo que

$$\mathbb{E}_0[\varphi^*] = \alpha \quad (o\ \le \alpha)$$

es la prueba más poderosa de nivel α.

Solución. Sea φ cualquier prueba tal que $\mathbb{E}_0[\varphi] \le \alpha$. Entonces

$$\mathbb{E}_1[\varphi^* - \varphi] = \int (\varphi^* - \varphi) f_1(x)\,\mathrm{d}x = \int (\varphi^* - \varphi)\frac{f_1(x)}{f_0(x)} f_0(x)\,\mathrm{d}x.$$

En el conjunto $\{\varphi^* = 1\}$ se tiene $f_1/f_0 \ge 1/c$ (equivalentemente $\Lambda \le c$); en $\{\varphi^* = 0\}$ se tiene $f_1/f_0 \le 1/c$.

Por tanto,

$$\mathbb{E}_1[\varphi^* - \varphi] \ge \frac{1}{c}\int (\varphi^* - \varphi) f_0(x)\,\mathrm{d}x = \frac{1}{c}\big(\mathbb{E}_0[\varphi^*] - \mathbb{E}_0[\varphi]\big) \ge 0.$$

En consecuencia,

$$\mathbb{E}_1[\varphi^*] \ge \mathbb{E}_1[\varphi].$$

4.3. Pruebas para media: z y t; dualidad IC–prueba

Teorema 4.5 (z-test para media con σ conocida)**.** *Si $X_i \sim N(\mu, \sigma^2)$ i.i.d. con σ conocida, para $H_0 : \mu = \mu_0$ vs $H_1 : \mu \ne \mu_0$,*

$$W = \frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0,1) \text{ bajo } H_0,$$

y la prueba de nivel α rechaza si $|W| \ge z_{\alpha/2}$.

Solución. Bajo H_0, $\overline{X} \sim N(\mu_0, \sigma^2/n)$; al estandarizar se obtiene $N(0,1)$. La región $\{|W| \ge z_{\alpha/2}\}$ tiene probabilidad α por definición del cuantil.

Teorema 4.6 (t-test para media con σ desconocida (normal))**.** *Si $X_i \sim N(\mu, \sigma^2)$ i.i.d. con σ desconocida, para $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$,*

$$T = \frac{\overline{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1} \text{ bajo } H_0,$$

y se rechaza si $|T| \geq t_{1-\alpha/2,n-1}$.

Solución. Es Theorem 3.10 con μ reemplazada por μ_0.

Proposición 4.7 (Dualidad IC–prueba)**.** *En normal con σ desconocida: el t-test bilateral de nivel α no rechaza $H_0 : \mu = \mu_0$ si y sólo si μ_0 pertenece al IC $1 - \alpha$ de Theorem 3.11.*

Solución. No rechazar equivale a $|T| < t_{1-\alpha/2,n-1}$, es decir

$$\left| \frac{\overline{X} - \mu_0}{S/\sqrt{n}} \right| < t_{1-\alpha/2,n-1} \iff \overline{X} - t_{1-\alpha/2,n-1} \frac{S}{\sqrt{n}} < \mu_0 < \overline{X} + t_{1-\alpha/2,n-1} \frac{S}{\sqrt{n}}.$$

Esto es exactamente "μ_0 cae dentro del IC".

4.4. Ejemplos resueltos de pruebas, incluyendo finanzas

Ejemplo 4.8 (Retorno medio positivo (finanzas))**.** Datos: $n = 60$, $\overline{X} = 0{,}0005$, $S = 0{,}012$. Prueba $H_0 : \mu \leq 0$ vs $H_1 : \mu > 0$ al 5 %.

Solución. La hipótesis nula relevante para un gestor es conservadora:

$$H_0 : \mu \leq 0 \qquad \text{vs} \qquad H_1 : \mu > 0.$$

La frontera de H_0 es $\mu_0 = 0$, así que usamos el estadístico

$$T = \frac{\overline{X} - \mu_0}{S/\sqrt{n}} = \frac{0{,}0005}{0{,}012/\sqrt{60}} = \frac{0{,}0005\sqrt{60}}{0{,}012} \approx 0{,}3228.$$

Con 59 grados de libertad y nivel $\alpha = 0{,}05$, el valor crítico unilateral es

$$t_{0{,}95,59} \approx 1{,}671.$$

La regla de decisión es:

$$\text{rechazar } H_0 \iff T \geq 1{,}671.$$

Como

$$0{,}323 < 1{,}671,$$

el estadístico cae en la región de no rechazo. Conclusión económica: el rendimiento medio observado es positivo, pero demasiado pequeño respecto a la volatilidad muestral para sostener una afirmación estadística fuerte de "alpha positivo" al 5 %.

Ejemplo 4.9 (Volatilidad excede límite (finanzas))**.** Supón normalidad, $n = 30$, $S^2 = 0{,}000144$ (var diaria). Probar $H_0 : \sigma^2 \leq 0{,}0001$ vs $H_1 : \sigma^2 > 0{,}0001$ al 5 %.

Solución. La empresa o mesa de riesgo quiere saber si la varianza verdadera rebasa un límite máximo permitido $\sigma_0^2 = 0{,}0001$. La prueba unilateral correcta usa

$$Q = \frac{(n-1)S^2}{\sigma_0^2} = \frac{29 \cdot 0{,}000144}{0{,}0001} = 41{,}76.$$

Bajo la frontera de la nula, $Q \sim \chi^2_{29}$. Como la alternativa es "más volatilidad", la región de rechazo vive en la cola derecha:

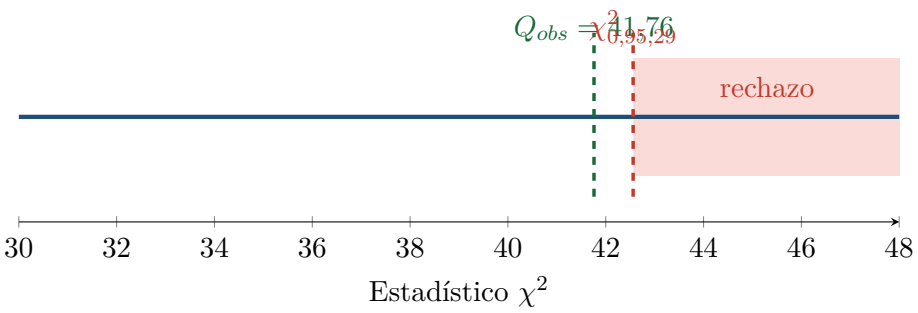
$$\text{rechazar } H_0 \iff Q \geq \chi^2_{0{,}95,29} \approx 42{,}56.$$

Pero

$$41{,}76 < 42{,}56.$$

Por tanto, no se rechaza H_0. La lectura práctica es fina: la volatilidad observada está cerca del límite, así que aunque no hay evidencia suficiente para declarar incumplimiento estadístico al 5 %, sí hay una señal de vigilancia porque el resultado queda muy próximo al umbral crítico.

Región de rechazo para la prueba sobre σ^2



Explicación de la figura. La zona roja representa la región de rechazo en la cola derecha: allí caerían valores de volatilidad muestral suficientemente grandes para concluir que el límite fue rebasado. Como $Q_{obs} = 41{,}76$ queda apenas antes del umbral, la evidencia es cercana pero todavía insuficiente al 5 %.

Ejemplo 4.10 (p-value bilateral en t-test)**.** Supón $n = 20$ y $t_{\text{obs}} = 2{,}1$ en una prueba bilateral sobre μ. ¿p-value aproximado?

Solución. Con $n = 20$, los grados de libertad son 19. En una prueba bilateral, el p-value se calcula como

$$p = 2\,\mathbb{P}(t_{19} \geq 2{,}1).$$

Usando tablas, sabemos que

$$t_{0{,}975,19} \approx 2{,}093.$$

Como el estadístico observado 2,1 está apenas por encima de ese cuantil, el área de cola bilateral es apenas menor que 0,05. Por ello,

$$p \approx 0{,}049\text{–}0{,}050.$$

Interpretación ejecutiva: el resultado es marginalmente significativo. En aplicaciones business, eso sugiere prudencia: una conclusión "significativa" existe, pero no es robusta ni holgada.

Ejemplo 4.11 (Proporción de días positivos supera 0.5)**.** En $n = 200$ días, el activo cerró con retorno positivo en 118 días. Probar $H_0 : p \leq 0{,}5$ vs $H_1 : p > 0{,}5$ al 5 % usando aproximación normal.

Solución. Primero calculamos la proporción observada:

$$\widehat{p} = \frac{118}{200} = 0{,}59.$$

Bajo $H_0 : p \leq 0{,}5$, la frontera relevante es $p_0 = 0{,}5$. El estadístico Wald es

$$W = \frac{\widehat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} = \frac{0{,}59 - 0{,}5}{\sqrt{0{,}5 \cdot 0{,}5/200}} \approx 2{,}545.$$

Al 5 % en una cola, el valor crítico normal es

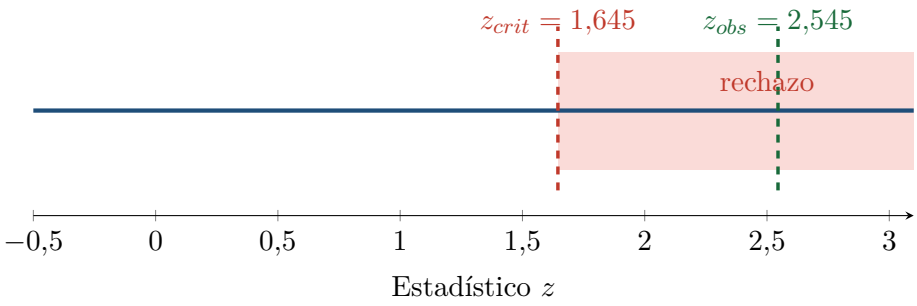
$$z_{0{,}05} \approx 1{,}645.$$

La regla de decisión es:

$$\text{rechazar } H_0 \iff W \geq 1{,}645.$$

Como $2{,}545 > 1{,}645$, rechazamos H_0. Lectura business: la estrategia tuvo días positivos en una fracción suficientemente alta como para sostener, estadísticamente, que la probabilidad de "ganar el día" supera el 50 %.

Región de rechazo para la prueba sobre proporción



Explicación de la figura. Aquí el estadístico observado sí entra en la franja roja. Eso visualiza por qué se rechaza H_0: la proporción observada de días positivos es lo bastante grande como para quedar dentro de la región crítica unilateral.

5. Regresión lineal: mínimos cuadrados, propiedades, inferencia

5.1. Modelo y estimadores OLS

Definición 5.1 (Regresión lineal simple)**.** Dados pares (x_i, y_i) con x_i fijos (o condicionados),

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \qquad \mathbb{E}[\varepsilon_i] = 0, \quad \mathrm{Var}(\varepsilon_i) = \sigma^2,$$

con $\mathrm{Cov}(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$. Para inferencia exacta se suele asumir además $\varepsilon_i \sim N(0, \sigma^2)$ i.i.d.

Define

$$\overline{x} = \frac{1}{n}\sum x_i, \quad \overline{y} = \frac{1}{n}\sum y_i, \quad S_{xx} = \sum (x_i - \overline{x})^2, \quad S_{xy} = \sum (x_i - \overline{x})(y_i - \overline{y}).$$

Teorema 5.2 (Solución OLS)**.** *Si $S_{xx} > 0$, los minimizadores de $\sum (y_i - \beta_0 - \beta_1 x_i)^2$ son*

$$\widehat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \qquad \widehat{\beta}_0 = \overline{y} - \widehat{\beta}_1\, \overline{x}.$$

Solución. Sea $Q(\beta_0, \beta_1) = \sum (y_i - \beta_0 - \beta_1 x_i)^2$. Deriva e iguala a cero:

$$\frac{\partial Q}{\partial \beta_0} = -2\sum (y_i - \beta_0 - \beta_1 x_i) = 0, \quad \frac{\partial Q}{\partial \beta_1} = -2\sum x_i (y_i - \beta_0 - \beta_1 x_i) = 0.$$

Estas ecuaciones normales equivalen a $\sum e_i = 0$ y $\sum x_i e_i = 0$. Resolviendo (por álgebra o centrado) se obtiene la fórmula. Unicidad: $S_{xx} > 0$.

Lema 5.3 (Propiedades de residuales)**.** *Con $\widehat{y}_i = \widehat{\beta}_0 + \widehat{\beta}_1 x_i$ y $e_i = y_i - \widehat{y}_i$:*

$$\sum_{i=1}^{n} e_i = 0, \qquad \sum_{i=1}^{n} x_i e_i = 0.$$

Solución. Son exactamente las ecuaciones normales.

5.2. Insesgadez, varianzas y Gauss–Markov (pruebas completas)

Teorema 5.4 (Insesgadez y varianzas de OLS)**.** *Bajo el modelo con $\mathbb{E}[\varepsilon_i] = 0$, $\mathrm{Var}(\varepsilon_i) = \sigma^2$ y covarianzas nulas,*

$$\mathbb{E}[\widehat{\beta}_1] = \beta_1, \quad \mathbb{E}[\widehat{\beta}_0] = \beta_0,$$
$$\mathrm{Var}(\widehat{\beta}_1) = \frac{\sigma^2}{S_{xx}}, \qquad \mathrm{Var}(\widehat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\overline{x}^2}{S_{xx}}\right).$$

Solución. Usa $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$. Calcula

$$S_{xy} = \sum (x_i - \overline{x})(y_i - \overline{y}) = \beta_1 S_{xx} + \sum (x_i - \overline{x})\varepsilon_i,$$

pues la parte con β_0 desaparece al centrar. Entonces

$$\widehat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \beta_1 + \frac{\sum (x_i - \overline{x})\varepsilon_i}{S_{xx}}.$$

Esperanza: $\mathbb{E}[\widehat{\beta}_1] = \beta_1$. Varianza (covarianzas nulas):

$$\mathrm{Var}(\widehat{\beta}_1) = \frac{1}{S_{xx}^2}\mathrm{Var}\Big(\sum (x_i - \overline{x})\varepsilon_i\Big) = \frac{1}{S_{xx}^2}\sum (x_i - \overline{x})^2 \sigma^2 = \frac{\sigma^2}{S_{xx}}.$$

Para $\widehat{\beta}_0 = \overline{y} - \widehat{\beta}_1 \overline{x}$ y $\overline{y} = \beta_0 + \beta_1 \overline{x} + \overline{\varepsilon}$:

$$\widehat{\beta}_0 = \beta_0 + \overline{\varepsilon} - \overline{x}(\widehat{\beta}_1 - \beta_1).$$

Usa $\mathrm{Var}(\overline{\varepsilon}) = \sigma^2/n$ y $\mathrm{Cov}(\overline{\varepsilon}, \sum (x_i - \overline{x})\varepsilon_i) = 0$ (porque $\sum (x_i - \overline{x}) = 0$) para obtener $\mathrm{Var}(\widehat{\beta}_0) = \sigma^2(1/n + \overline{x}^2/S_{xx})$.

Teorema 5.5 (Gauss–Markov (BLUE))**.** *Bajo las hipótesis lineales, $\widehat{\beta}_1$ es BLUE: entre estimadores lineales insesgados de β_1, tiene varianza mínima.*

Solución. Sea $\widetilde{\beta}_1 = \sum a_i Y_i$. Insesgadez impone $\sum a_i = 0$ y $\sum a_i x_i = 1$. Entonces $\mathrm{Var}(\widetilde{\beta}_1) = \sigma^2 \sum a_i^2$. Minimiza $\sum a_i^2$ con multiplicadores: $a_i = \lambda + \mu x_i$. De $\sum a_i = 0$ y $\sum a_i x_i = 1$ se obtiene

$$a_i = \frac{x_i - \overline{x}}{S_{xx}}.$$

Entonces $\widetilde{\beta}_1 = \sum \frac{x_i - \overline{x}}{S_{xx}} Y_i = S_{xy}/S_{xx} = \widehat{\beta}_1$.

5.3. Inferencia exacta bajo normalidad

Proposición 5.6 (Estimador insesgado de σ^2 en regresión)**.** *Con residuales $e_i = y_i - \widehat{y}_i$, define*

$$\widehat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^{n} e_i^2.$$

Bajo normalidad de errores, $\mathbb{E}[\widehat{\sigma}^2] = \sigma^2$.

Solución. En el modelo normal, $\sum e_i^2/\sigma^2 \sim \chi^2_{n-2}$ (se pierden 2 g.l. por estimar β_0, β_1). Entonces $\mathbb{E}[\sum e_i^2] = (n-2)\sigma^2$ y dividir por $n-2$ da insesgadez.

Corolario 5.7 (t-test/IC para β_1)**.** *Bajo normalidad,*

$$\frac{\widehat{\beta}_1 - \beta_1}{\sqrt{\widehat{\sigma}^2/S_{xx}}} \sim t_{n-2}, \quad \beta_1 \in \left[\widehat{\beta}_1 \pm t_{1-\alpha/2,n-2} \sqrt{\frac{\widehat{\sigma}^2}{S_{xx}}} \right].$$

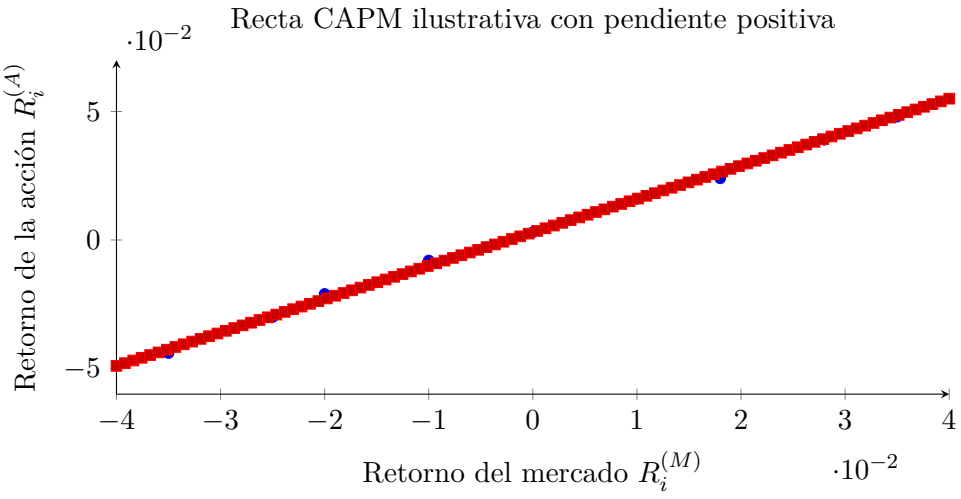
Solución. $\widehat{\beta}_1$ es normal con varianza σ^2/S_{xx}. Además, $\sum e_i^2/\sigma^2 \sim \chi^2_{n-2}$ e independencia por proyección ortogonal. Por definición, el cociente es t_{n-2}.

5.4. Ejemplos resueltos de regresión con finanzas

Ejemplo 5.8 (CAPM: beta de una acción)**.** Sea $y_i = R_i^{(A)}$ y $x_i = R_i^{(M)}$. Modelo: $R^{(A)} = \beta_0 + \beta_1 R^{(M)} + \varepsilon$. Queremos estimar β_1 y hacer IC.

Solución. Calcula $\widehat{\beta}_1 = S_{xy}/S_{xx}$ con datos. Luego $\widehat{\sigma}^2 = \sum e_i^2/(n-2)$. IC 95 %:

$$\widehat{\beta}_1 \pm t_{0{,}975,n-2} \sqrt{\widehat{\sigma}^2/S_{xx}}.$$



Ejemplo 5.9 (Duración empírica: retorno de bono vs cambio de yield)**.** Sea y_i retorno del bono y $x_i = \Delta y_i$ cambio diario del yield. Si $\widehat{\beta}_1 < 0$, el signo concuerda con duración (sube yield, baja precio).

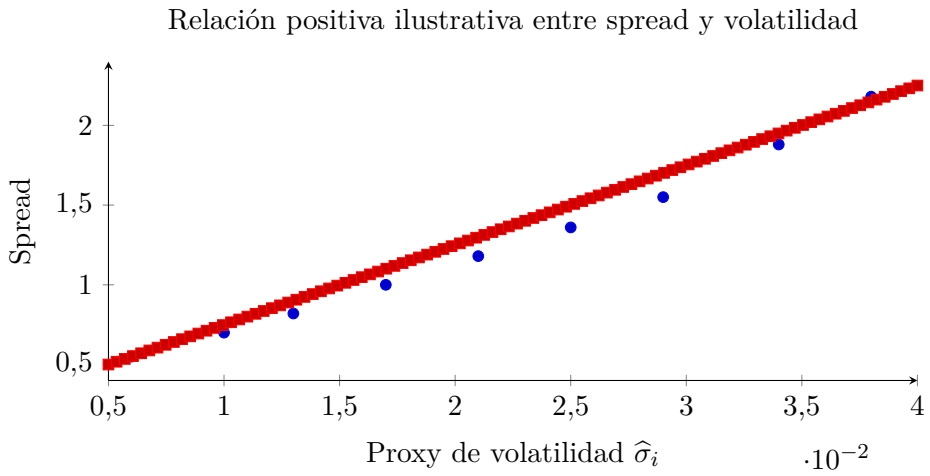
Solución. Ajusta OLS y prueba $H_0 : \beta_1 = 0$ con estadístico t. Un $\widehat{\beta}_1$ significativamente negativo apoya la sensibilidad.

Ejemplo 5.10 (Volatilidad vs volumen)**.** Sea $y_i = |R_i|$ y $x_i = \log(\text{Vol}_i)$.

Solución. Ajusta OLS. Un $\widehat{\beta}_1 > 0$ sugiere asociación positiva entre actividad y magnitud de movimientos.

Ejemplo 5.11 (Spread vs volatilidad)**.** Sea $y_i = \text{spread}_i$ y $x_i = \widehat{\sigma}_i$ (proxy).

Solución. Ajusta OLS y prueba pendiente positiva. Interpretación microestructural: spreads más altos cuando el riesgo/información es mayor.



A. Apéndice A: Prerrequisitos probabilísticos (recordatorio)

Este apéndice resume la parte de *Probabilidad* que realmente sostiene la estadística inferencial del texto. La idea es sencilla: antes de estimar, construir intervalos o definir regiones de rechazo, necesitamos saber qué es una variable aleatoria, cómo se comportan la esperanza y la varianza, por qué la independencia simplifica cálculos, y cómo las leyes límite conectan cantidades muestrales con distribuciones asintóticas. En varios de los ejercicios del apéndice siguiente se añadirá explícitamente una línea titulada *Prerrequisitos de Probabilidad usados*, para que se vea con precisión qué piezas de este apéndice intervienen.

A.1. Espacios de probabilidad y variables aleatorias

Definición A.1 (Espacio de probabilidad)**.** Un espacio de probabilidad es $(\Omega, \mathcal{F}, \mathbb{P})$: Ω espacio muestral, $\mathcal{F}$ sigma-álgebra, $\mathbb{P}$ medida de probabilidad.

Definición A.2 (Variable aleatoria, distribución)**.** Una v.a. es $X : (\Omega, \mathcal{F}) \to (\mathbb{R}, \mathcal{B})$ medible. Su CDF es $F_X(x) = \mathbb{P}(X \leq x)$.

A.2. Esperanza, varianza, covarianza (fórmulas mínimas)

Proposición A.3 (Linealidad de la esperanza)**.** *Para constantes a, b y v.a. integrables X, Y:* $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$.

Proposición A.4 (Varianza y covarianza)**.**

$$\mathrm{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2, \quad \mathrm{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Si X, Y son independientes y con segundos momentos finitos, entonces $\mathrm{Cov}(X, Y) = 0$.

Proposición A.5 (Varianza de suma)**.** *Si X_i son no correlacionadas:*

$$\mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \mathrm{Var}(X_i).$$

En particular, si i.i.d. con varianza σ^2, entonces $\mathrm{Var}(\overline{X}) = \sigma^2/n$.

Observación A.6 (Qué aporta esta subsección). Las identidades de esperanza y varianza permiten pasar de observaciones individuales a estadísticos muestrales. En particular, casi todos los cálculos de error estándar del documento parten de dos hechos:

$$\mathbb{E}[\overline{X}] = \mu, \qquad \mathrm{Var}(\overline{X}) = \frac{\sigma^2}{n},$$

y éstos dependen directamente de linealidad de la esperanza e independencia.

A.3. Desigualdades esenciales

Teorema A.7 (Markov)**.** *Si $X \geq 0$ y $\mathbb{E}[X] < \infty$, entonces $\mathbb{P}(X \geq a) \leq \mathbb{E}[X]/a$ para $a > 0$.*

Teorema A.8 (Chebyshev)**.** *Si $\mathrm{Var}(X) < \infty$, entonces $\mathbb{P}(|X - \mathbb{E}[X]| \geq \varepsilon) \leq \mathrm{Var}(X)/\varepsilon^2$.*

A.4. Leyes límite: LLN y CLT

Teorema A.9 (Ley débil de los grandes números (WLLN)). *Si X_i i.i.d. con $\mathbb{E}[X_i] = \mu$ y $\mathrm{Var}(X_i) < \infty$, entonces $\overline{X} \to \mu$ en probabilidad.*

Solución. Se prueba con Chebyshev como en Theorem 2.9.

Teorema A.10 (Teorema central del límite (CLT)). *Si X_i i.i.d. con media μ y varianza $\sigma^2 < \infty$, entonces $\sqrt{n}(\overline{X} - \mu)/\sigma \Rightarrow N(0,1)$.*

Observación A.11. En inferencia clásica, CLT justifica IC y pruebas aproximadas fuera de normalidad cuando n es grande. En lenguaje operativo: si una media muestral está bien centrada y su dispersión se reduce como $1/n$, entonces la normal aparece como aproximación universal tras reescalar por $\sqrt{n}$.

A.5. Normal, chi-cuadrada y t: relaciones mínimas

Proposición A.12 (Normal estándar). *$Z \sim N(0,1)$ si su densidad es $\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$. Cuantil z_α: $\mathbb{P}(Z \geq z_\alpha) = \alpha$.*

Proposición A.13 (Chi-cuadrada). *Si $Z_1, \ldots, Z_\nu$ i.i.d. $N(0,1)$, entonces $\sum_{i=1}^{\nu} Z_i^2 \sim \chi^2_\nu$.*

Proposición A.14 (t de Student). *Si $Z \sim N(0,1)$, $U \sim \chi^2_\nu$ independientes, entonces*

$$T = \frac{Z}{\sqrt{U/\nu}} \sim t_\nu.$$

Observación A.15 (Lectura inferencial). Estas tres familias aparecen una y otra vez:

(1) la normal para pivotes centrados y estandarizados;

(2) la chi-cuadrada para varianzas bajo normalidad;

(3) la t cuando la varianza poblacional es desconocida y se sustituye por S.

Por eso las regiones de rechazo y los intervalos del texto tienen fronteras dadas por cuantiles z_α, $\chi^2_{\alpha,\nu}$ o $t_{\alpha,\nu}$.

A.6. Transformaciones y método delta (recordatorio corto)

Proposición A.16 (Transformación monótona en IC). *Si $[L, U]$ es IC para θ y g es monótona creciente, entonces $[g(L), g(U)]$ es IC para $g(\theta)$.*

Observación A.17. Ej.: IC de $\sigma^2 \Rightarrow$ IC de σ usando raíz cuadrada.

B. Apéndice B: Ejercicios y soluciones completas

Guía de lectura. En las soluciones seleccionadas de este apéndice se indica explícitamente qué parte del Apéndice A está siendo usada. El objetivo es conectar cada técnica inferencial con su fundamento probabilístico mínimo.

B.1. Ejercicios con soluciones

Ejercicio B.1 (MSE y sesgo: traslación de la media)**.** Sea $\widehat{\Theta} = \overline{X} + c$ un estimador de μ, con $c \in \mathbb{R}$ constante. Encuentra el sesgo y el error cuadrático medio (MSE). Determina el valor de c que minimiza el MSE.

Solución. Prerrequisitos de Probabilidad usados. Linealidad de la esperanza y varianza de la media muestral del Section A.2. El paso clave es que sumar una constante cambia la esperanza pero no la varianza.

Sesgo:

$$\mathbb{E}[\overline{X} + c] - \mu = (\mu + c) - \mu = c.$$

Varianza:

$$\mathrm{Var}(\overline{X} + c) = \mathrm{Var}(\overline{X}) = \frac{\sigma^2}{n}.$$

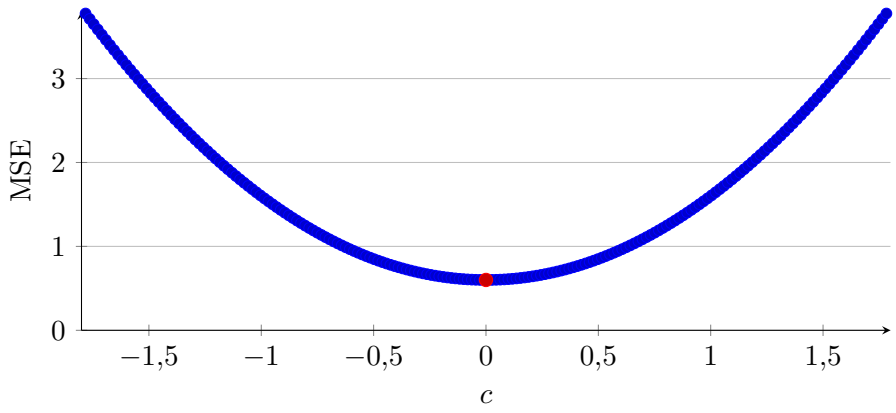
Por tanto, el error cuadrático medio es

$$\mathrm{MSE} = \mathrm{Var}(\overline{X} + c) + (\text{sesgo})^2 = \frac{\sigma^2}{n} + c^2.$$

Esta expresión se minimiza cuando $c^* = 0$. Por lo tanto, el mejor estimador dentro de esta familia (en términos de MSE) es

$$\widehat{\Theta} = \overline{X}.$$

El MSE es una parábola con mínimo en $c = 0$



Explicación de la figura. La gráfica muestra que desplazar el estimador $\overline{X}$ por una constante c introduce sesgo cuadrático c^2. Como la varianza permanece fija en σ^2/n, toda desviación de $c = 0$ aumenta el MSE.

Ejercicio B.2 (IC para σ^2 y anualización)**.** Con $n = 20$ y $S^2 = 0{,}0004$ (varianza diaria de retornos), construye un IC 95 % para σ^2 bajo normalidad. Luego da IC para σ y para σ_{anual}.

Solución. Prerrequisitos de Probabilidad usados. Relación entre normal y chi-cuadrada del Section A.5, junto con transformación monótona de intervalos del Section A.6. La parte probabilística profunda aquí es que, bajo normalidad,

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1},$$

y eso es exactamente lo que genera el pivote para el intervalo.

Grados de libertad: $\nu = n - 1 = 19$. Por Theorem 3.9 con $\alpha = 0{,}05$:

$$\sigma^2 \in \left[\frac{19S^2}{\chi^2_{0{,}975,19}},\ \frac{19S^2}{\chi^2_{0{,}025,19}} \right].$$

Usando valores típicos (aprox.): $\chi^2_{0{,}975,19} \approx 32{,}85$ y $\chi^2_{0{,}025,19} \approx 8{,}91$. Entonces

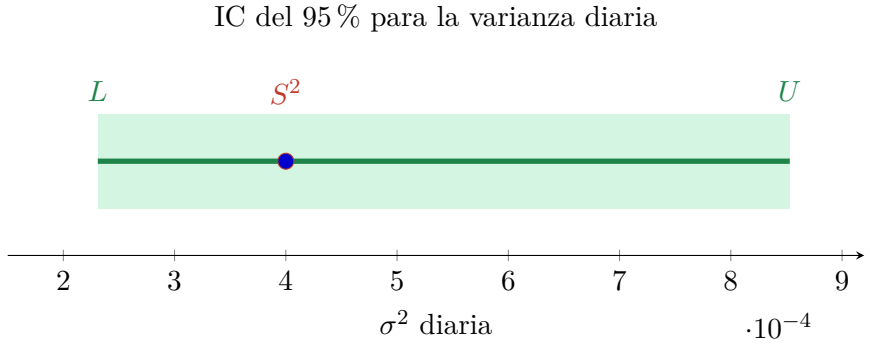
$$\text{LI} = \frac{19 \cdot 0{,}0004}{32{,}85} \approx \frac{0{,}0076}{32{,}85} \approx 0{,}000231, \quad \text{LS} = \frac{19 \cdot 0{,}0004}{8{,}91} \approx \frac{0{,}0076}{8{,}91} \approx 0{,}000853.$$

IC para σ: tomar raíces:

$$\sigma \in [\sqrt{0{,}000231}, \sqrt{0{,}000853}] \approx [0{,}0152,\ 0{,}0292].$$

IC para anualizada: multiplica por $\sqrt{252} \approx 15{,}874$:

$$\sigma_{\text{anual}} \in [0{,}0152 \cdot 15{,}874,\ 0{,}0292 \cdot 15{,}874] \approx [0{,}241,\ 0{,}463].$$



Explicación de la figura. El punto central representa la varianza muestral $S^2 = 0{,}0004$ y el segmento horizontal muestra el rango de valores plausibles para σ^2. Después, el mismo intervalo se transforma de manera monótona a escalas de volatilidad diaria y anualizada.

Ejercicio B.3 (t-test unilateral (retornos))**.** Retornos diarios: $n = 60$, $\overline{X} = 0{,}0005$, $S = 0{,}012$. Prueba $H_0 : \mu \leq 0$ vs $H_1 : \mu > 0$ al 5 %.

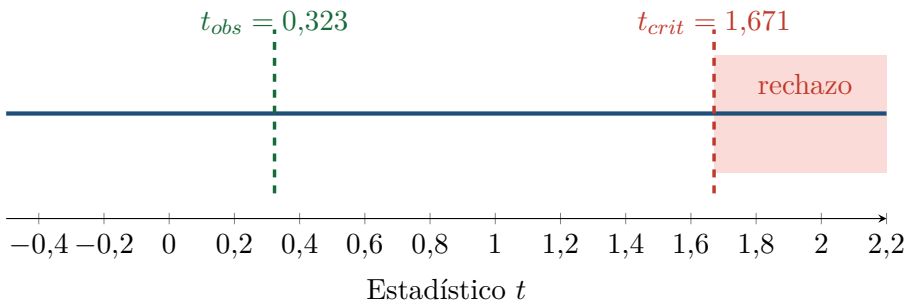
Solución. Prerrequisitos de Probabilidad usados. Distribución t de Student del Section A.5; además, implícitamente se usa que $\overline{X}$ resume la muestra y que su dispersión depende de $\text{Var}(\overline{X}) = \sigma^2/n$ del Section A.2. La región de rechazo se construye con un cuantil $t_{0{,}95,59}$, es decir, con una frontera probabilística.

Es exactamente el Ejemplo de la sección de pruebas:

$$t_{\text{obs}} = \frac{0{,}0005}{0{,}012/\sqrt{60}} \approx 0{,}323.$$

Crítico $t_{0{,}95,59} \approx 1{,}671$. No se rechaza H_0.

Región de rechazo unilateral y posición de t_{obs}



Explicación de la figura. Como $t_{obs} = 0{,}323$ queda claramente a la izquierda del valor crítico 1,671, el estadístico observado no entra en la región de rechazo. Por eso la evidencia a favor de $\mu > 0$ es insuficiente al 5 %.

Ejercicio B.4 (CAPM: IC para beta)**.** Con $n = 120$, $S_{xx} = 0{,}018$, $\widehat{\sigma}^2 = 0{,}00009$, y $\widehat{\beta}_1 = 1{,}15$, construye un IC 95 % para β_1.

Solución. Prerrequisitos de Probabilidad usados. Uso de cuantiles de la distribución t del Section A.5 y, detrás del error estándar, la lógica de esperanza/varianza de combinaciones lineales del Section A.2. En regresión lineal, el intervalo sale de estandarizar el estimador y compararlo con una ley t.

Grados de libertad: $n - 2 = 118$. Error estándar:

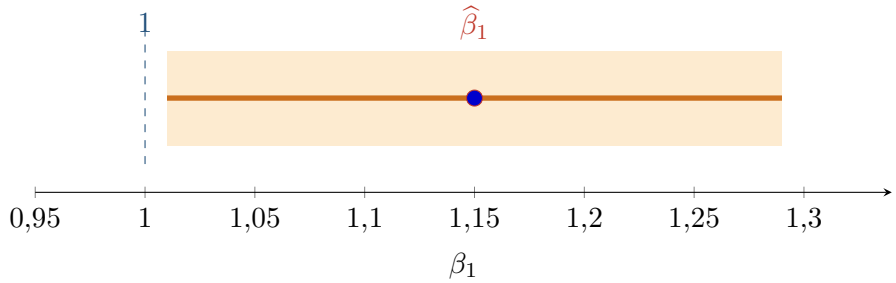
$$\widehat{\mathrm{se}}(\widehat{\beta}_1) = \sqrt{\frac{\widehat{\sigma}^2}{S_{xx}}} = \sqrt{\frac{0{,}00009}{0{,}018}} = \sqrt{0{,}005} = 0{,}0707107.$$

Cuantil $t_{0{,}975,118} \approx 1{,}98$ (muy cercano a 1.96). Semiancho $\approx 1{,}98 \cdot 0{,}07071 \approx 0{,}1400$. Por tanto:

$$\beta_1 \in [1{,}15 - 0{,}14,\ 1{,}15 + 0{,}14] = [1{,}01,\ 1{,}29] \text{ (aprox.)}.$$

Interpretación: beta es consistentemente mayor que 1 (casi justo), alta exposición al mercado.

IC del 95 % para la beta CAPM



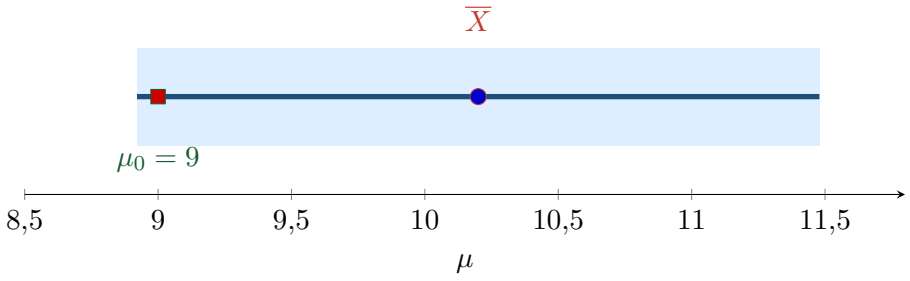
Explicación de la figura. El segmento muestra que casi todo el rango plausible para β_1 está por encima de 1. Eso sugiere una acción con sensibilidad al mercado ligeramente superior a la unidad.

Ejercicio B.5 (Ejercicio extra: IC de media y decisión por dualidad)**.** Con $n = 16$, $\overline{X} = 10{,}2$, $S = 2{,}4$ y suponer normalidad. (i) Construye IC 95 % para μ. (ii) Decide si rechazas $H_0 : \mu = 9$ al 5 % (bilateral) usando dualidad.

Solución. Prerrequisitos de Probabilidad usados. Distribución t del Section A.5 y la interpretación de cuantiles probabilísticos. La dualidad con la prueba bilateral se apoya en que el mismo pivote aleatorio produce simultáneamente el intervalo y la región de rechazo.

(i) $\nu = 15$, $t_{0{,}975,15} \approx 2{,}131$. Semiancho: $2{,}131 \cdot 2{,}4/\sqrt{16} = 2{,}131 \cdot 0{,}6 = 1{,}2786$. IC: $10{,}2 \pm 1{,}279 \Rightarrow [8{,}921,\ 11{,}479]$. (ii) Como $9 \in [8{,}921, 11{,}479]$, *no* se rechaza H_0 al 5 %.

Dualidad entre IC y prueba bilateral



Explicación de la figura. El valor nulo $\mu_0 = 9$ cae dentro del intervalo de confianza del 95 %. Esa inclusión visualiza inmediatamente la dualidad: si el valor hipotético pertenece al IC, la prueba bilateral no rechaza H_0 al mismo nivel.